

大数据时代下人工智能技术的应用与创新

# 机器学习算法

陈一帅

[yschen@bjtu.edu.cn](mailto:yschen@bjtu.edu.cn)

# 内容

- 算法
- 模型
- 性能

# 内容

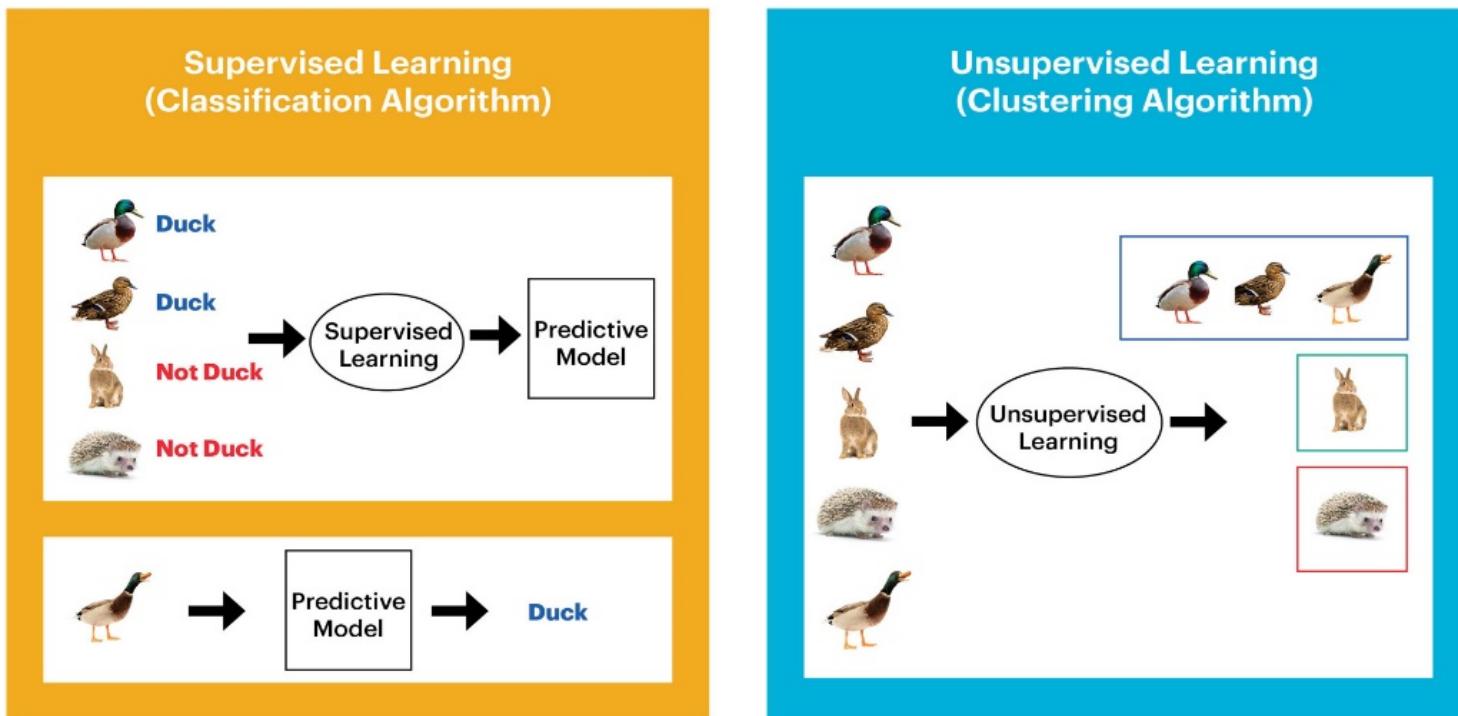
- 算法
- 模型
- 性能

# 算法

- 有监督
- 无监督

# 有监督和无监督

- 有监督：已知正确答案，比如图片类别
- 无监督：没有正确答案，比如只有图片



Western Digital.

# 1) 有监督学习

Supervised learning

已知正确答案

# 步骤

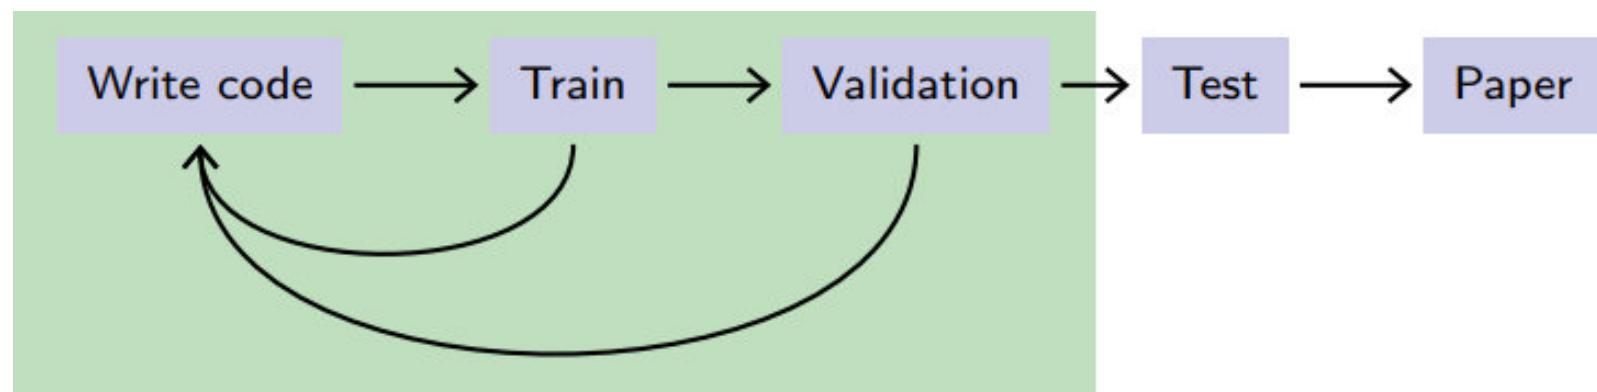
1. 打标
2. 训练
3. 测试

# 1) 打标

1. 收集数据集
2. 打标
  - 给图片标注：“猫”，“狗”
3. 把数据分为三部分
  - 训练集：训练模型
  - 验证集：选择模型参数
  - 测试集：测试模型准确度

## 2) 训练模型

1. 训练: 训练模型
2. 验证: 选择模型参数
3. 测试: 在测试集上, 对模型进行最终的评估



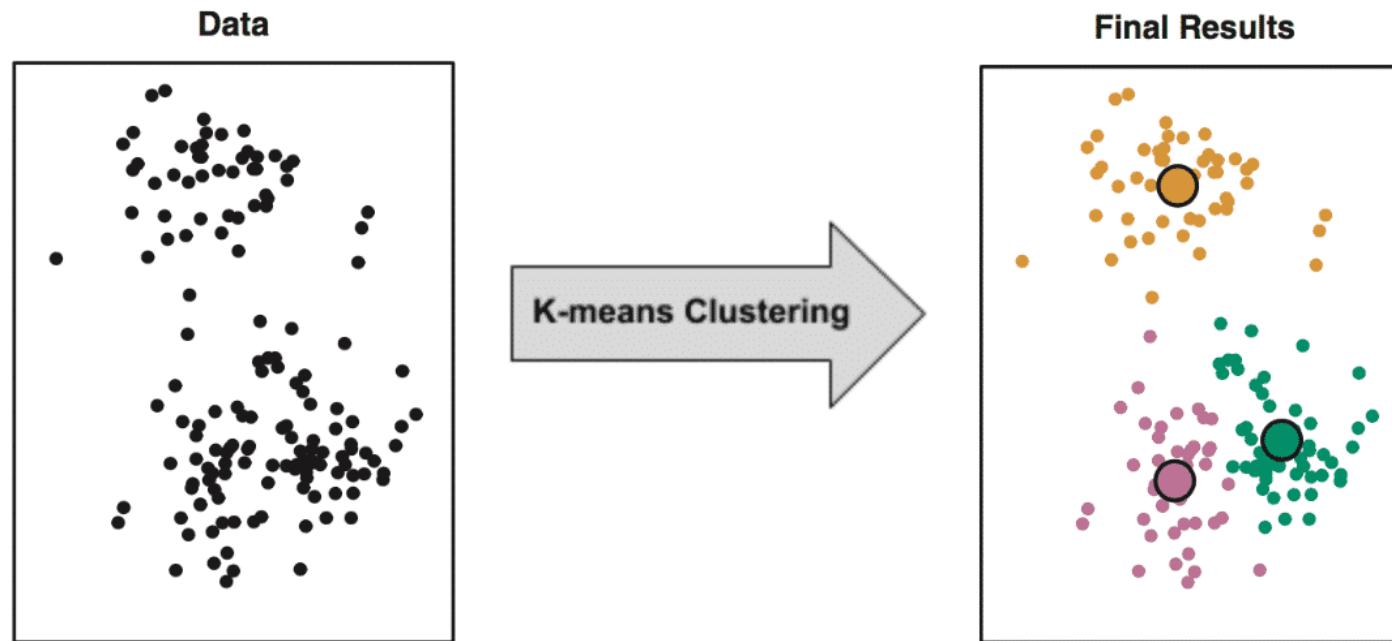
## 2) 无监督学习

Unsupervised learning

有数据，无标签，就在数据上寻找规律

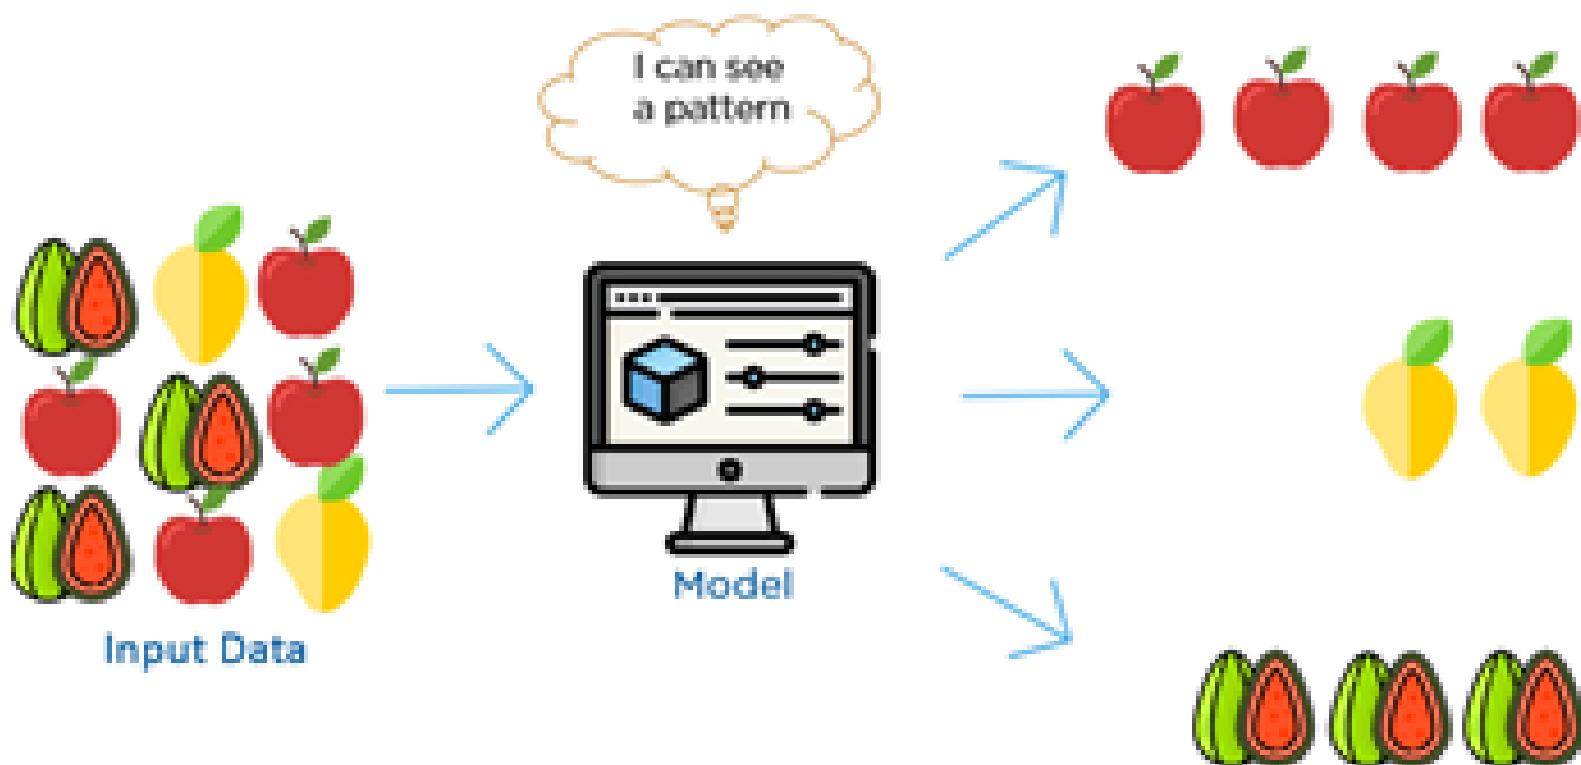
# 1) 聚类

指定聚为3个簇



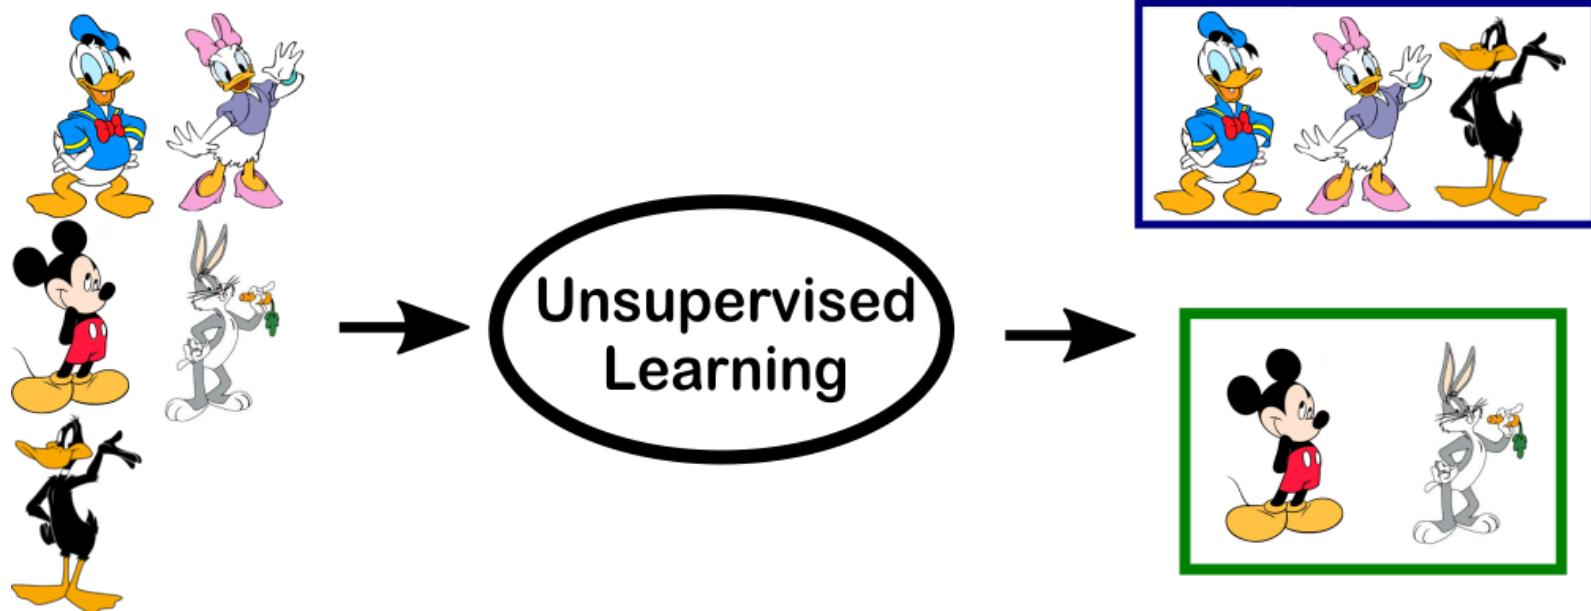
# 1) 聚类

- 聚完类后，观察各簇，获得其物理意义
- 结果可能是这样的



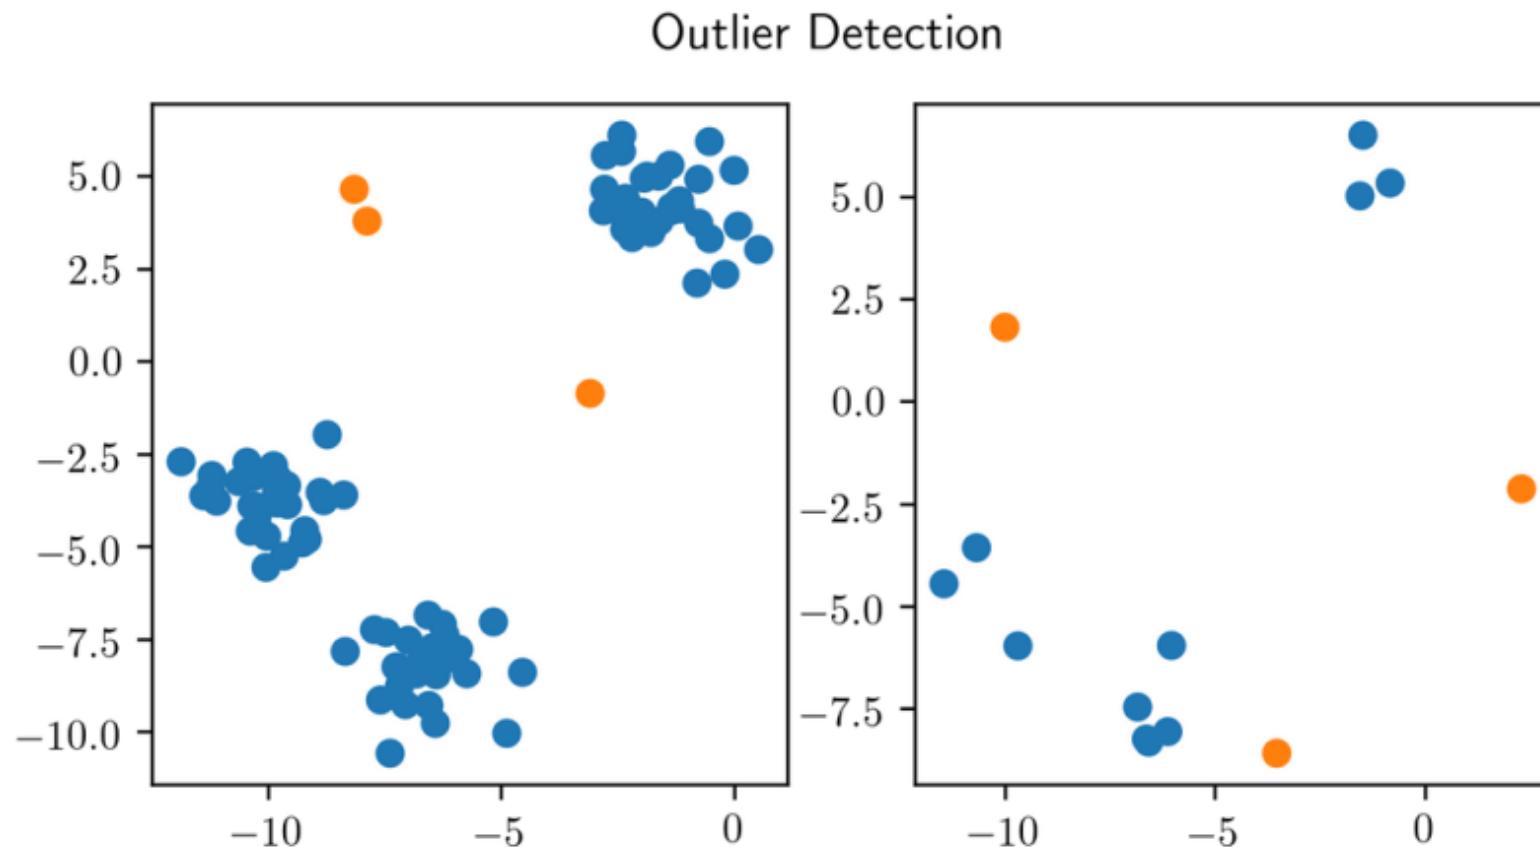
# 1) 聚类

- 结果也可能是这样的



## 2) 异常检测

发现离群的点，即异常点



# 小结：学习类型

1. 有监督学习
  - 已知正确答案（标签）
2. 无监督学习
  - 从纯数据中发现规律

# 内容

- 算法
- 模型
- 性能

# 模型训练方法

在错误中学习

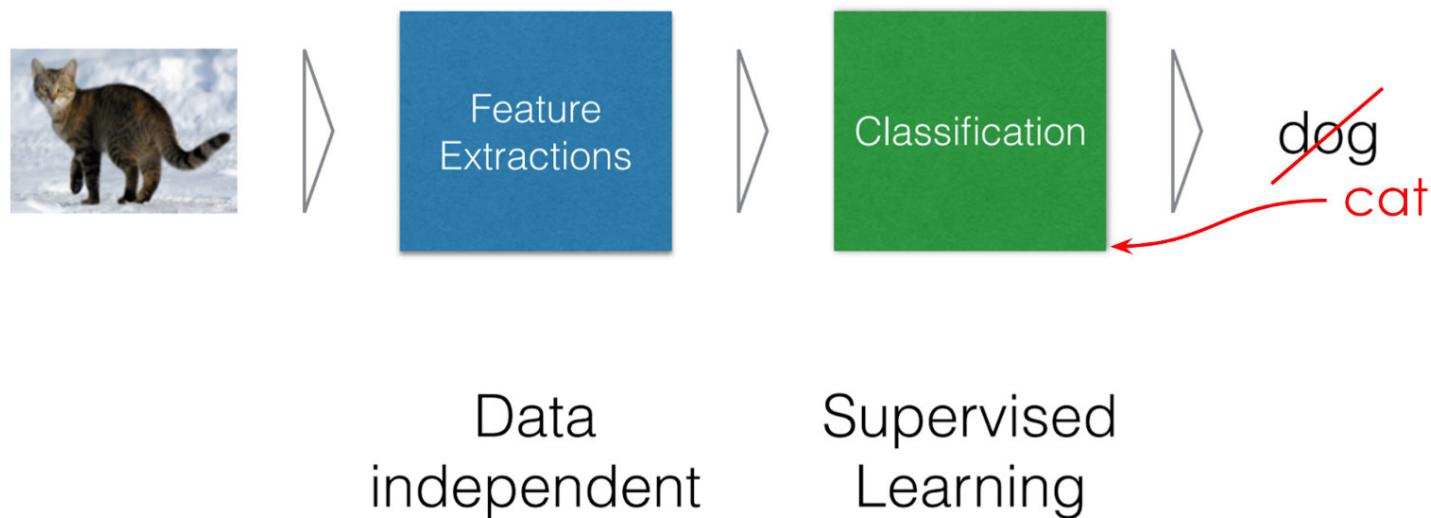
# 大脑学习过程

- 根据实验结果，不断创建、强化、弱化神经元之间连接
- 也就是调整连接的权重： $w$



# 机器学习的学习过程

- 出现错误，调整模型参数



# 感知机的学习过程

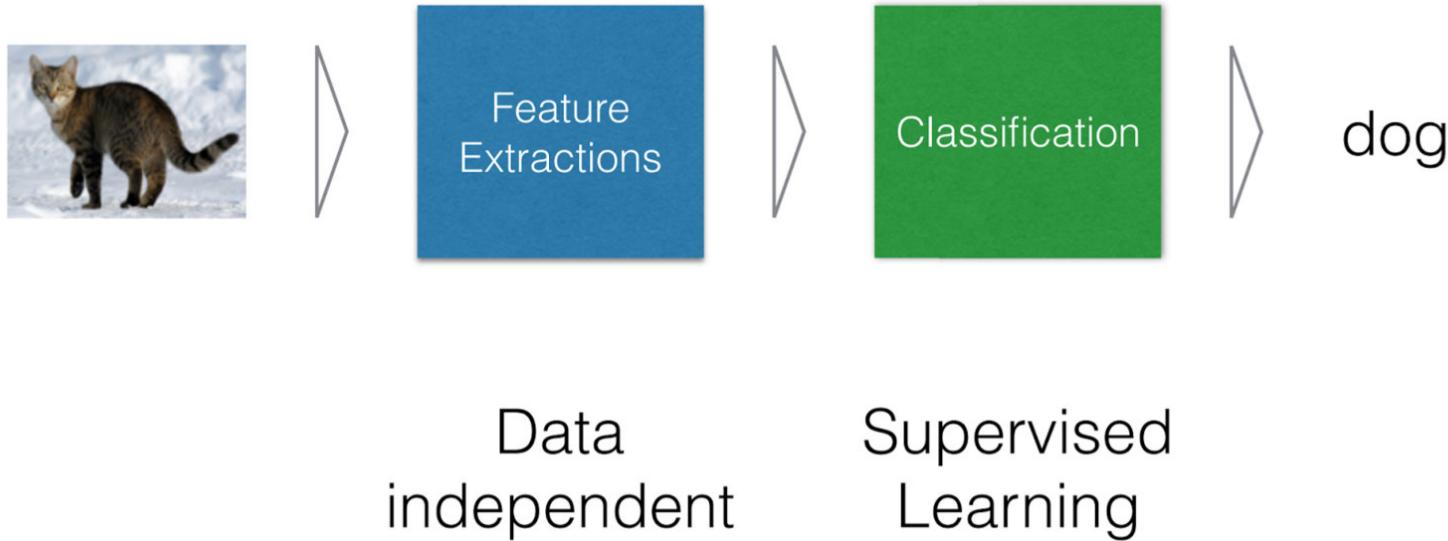
- 发现错误，调整 $W$ ，调整决策边界

# 深度学习

Deep Learning

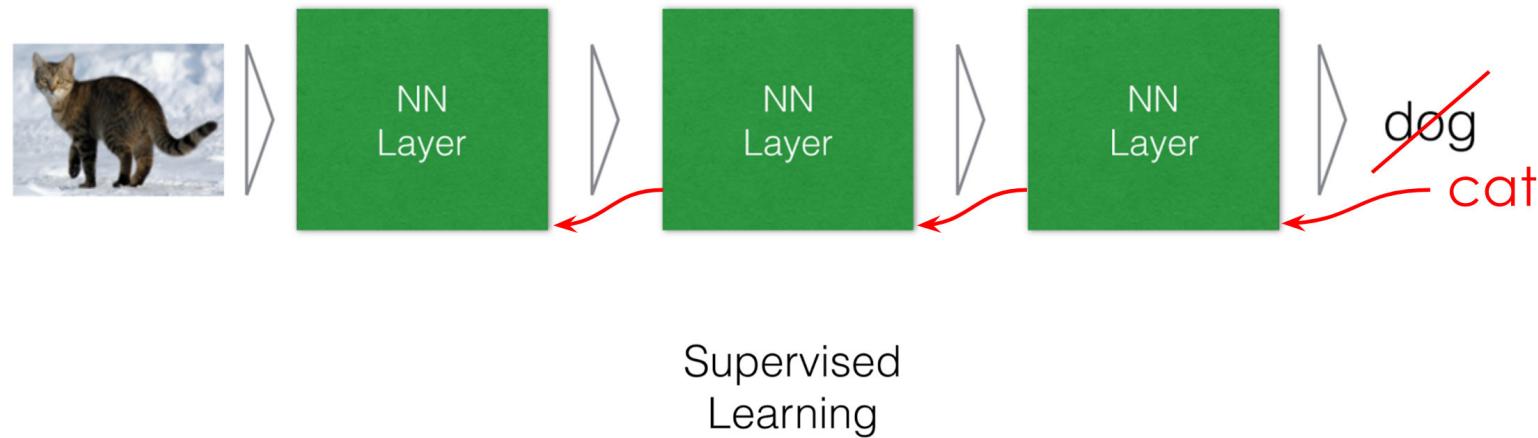
# 机器学习

- 先提取图片特征
- 然后根据这些特征进行学习



# 深度学习

- 不专门提取数据特征
- 将原始数据直接送入多层神经元网络进行学习
- 出现错误，调整到底



# 常用结构

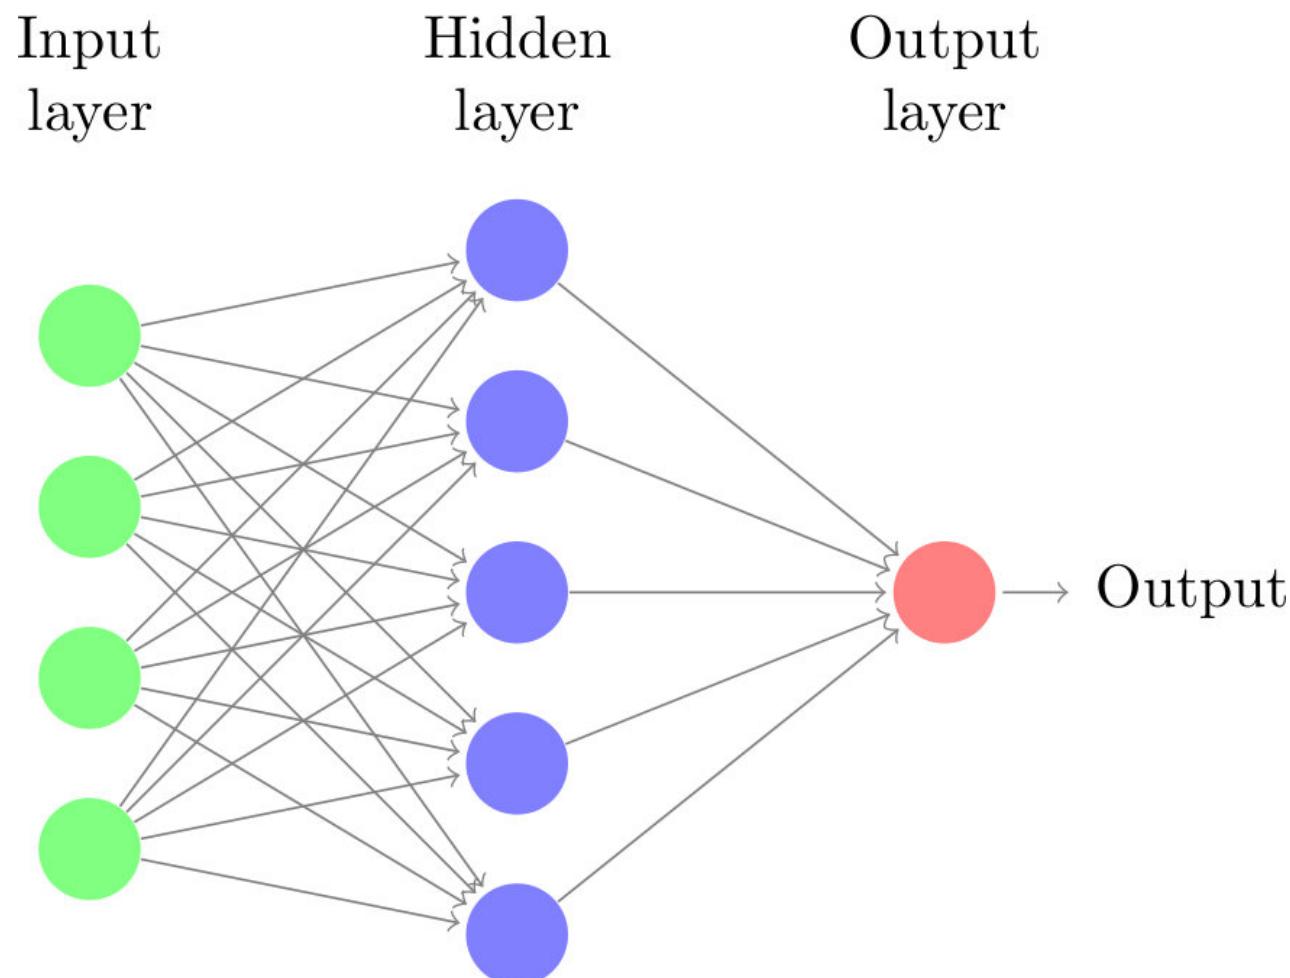
FFN、CNN

# 前向神经元网络

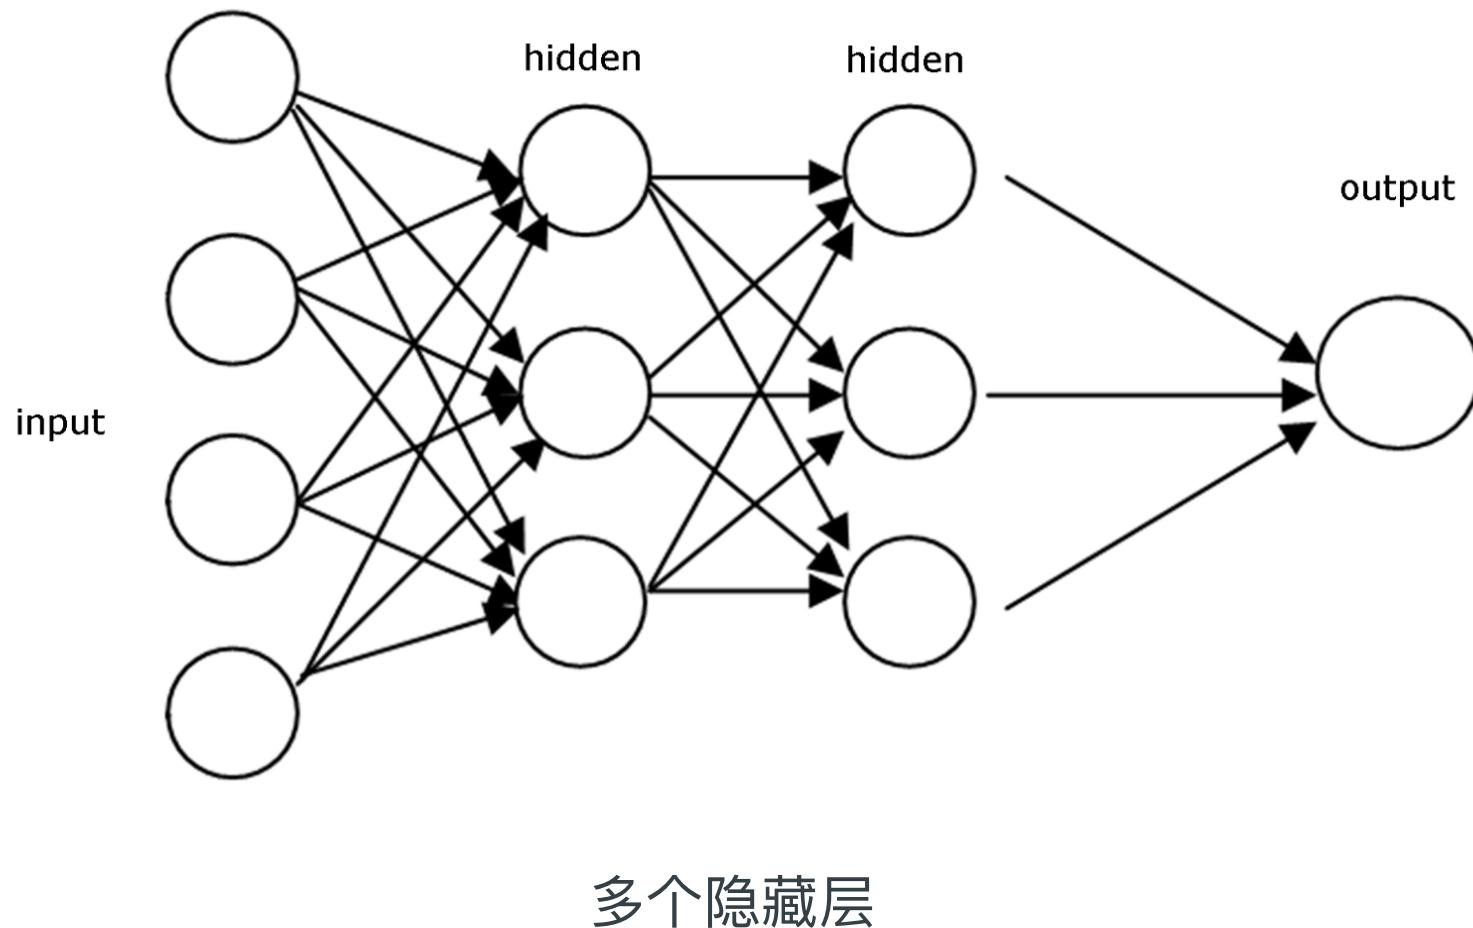
FFN: Feed Forward Network

# 前向神经元网络

输入层，隐藏层，输出层



# 深度神经元网络



# 深度的好处

越深，模型能力越强

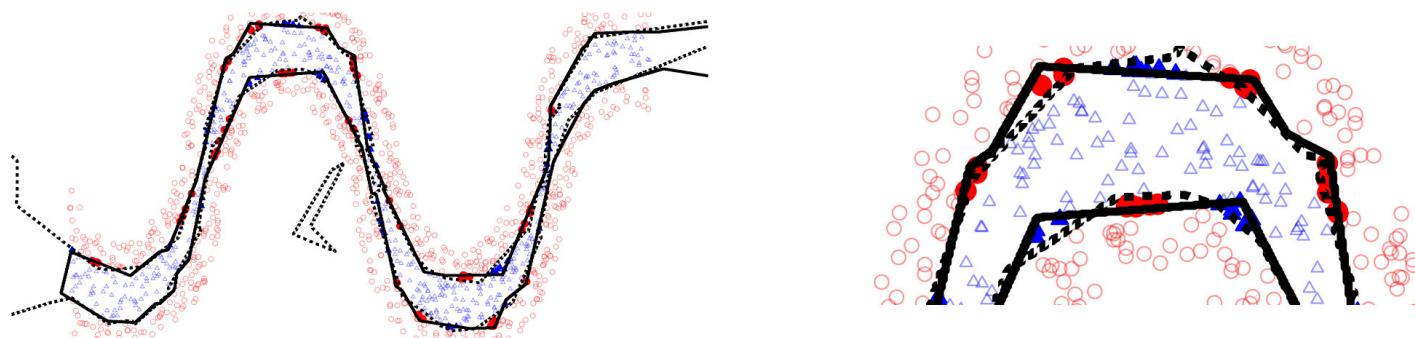
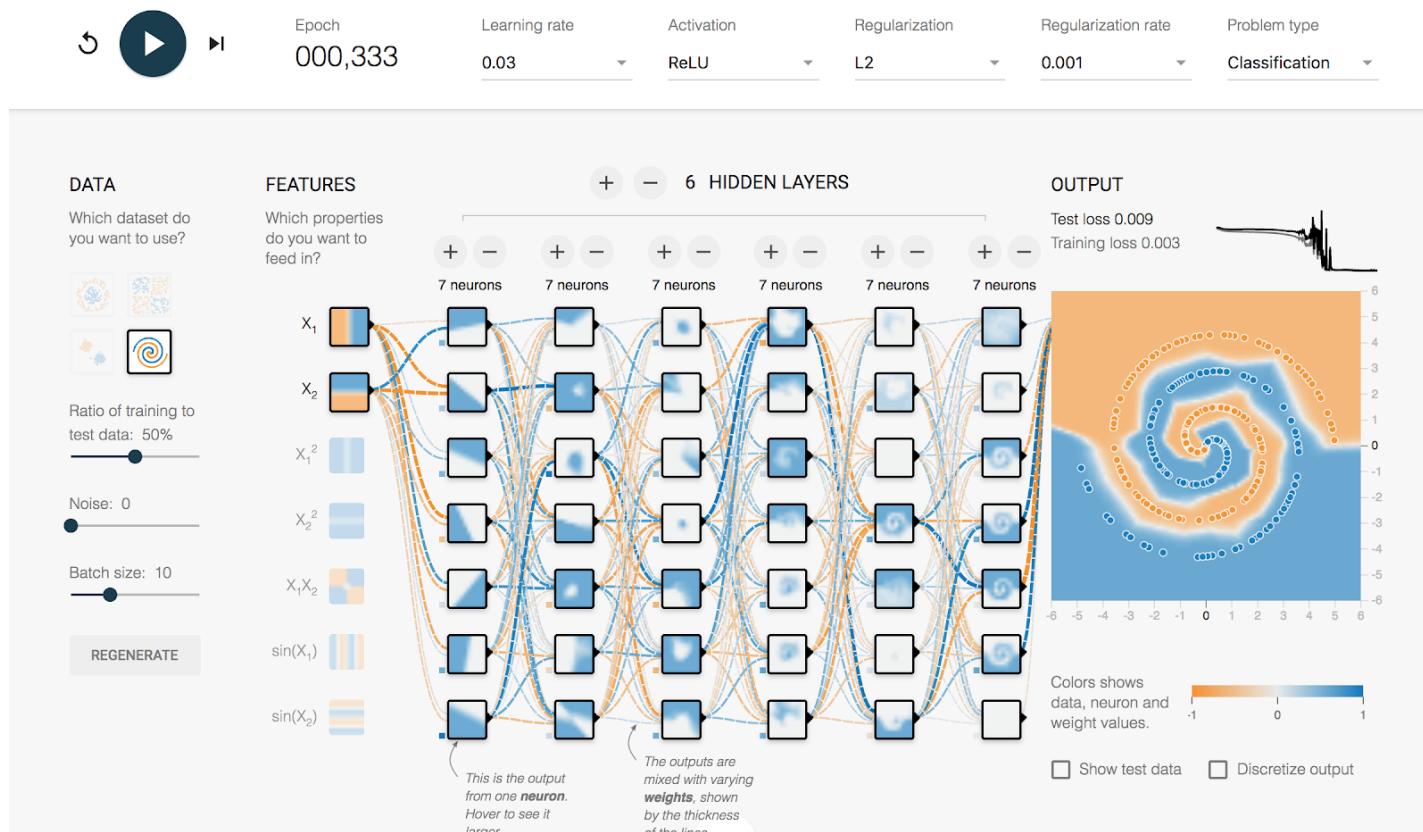


Figure 1: Binary classification using a shallow model with 20 hidden units (solid line) and a deep model with two layers of 10 units each (dashed line). The right panel shows a close-up of the left panel. Filled markers indicate errors made by the shallow model.

# FNN练习

- 基于浏览器的TensorFlow实验平台
- <http://playground.tensorflow.org>

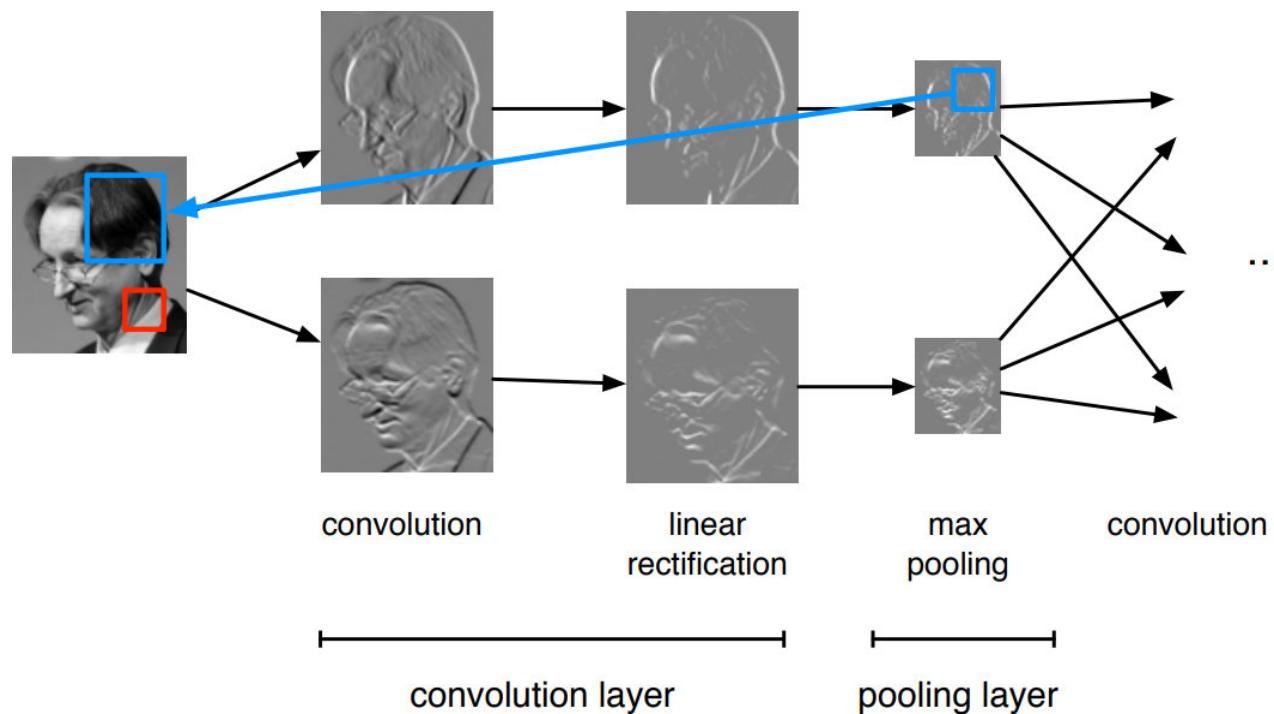


# 卷积神经元网络

CNN: Convolutional Neural Network

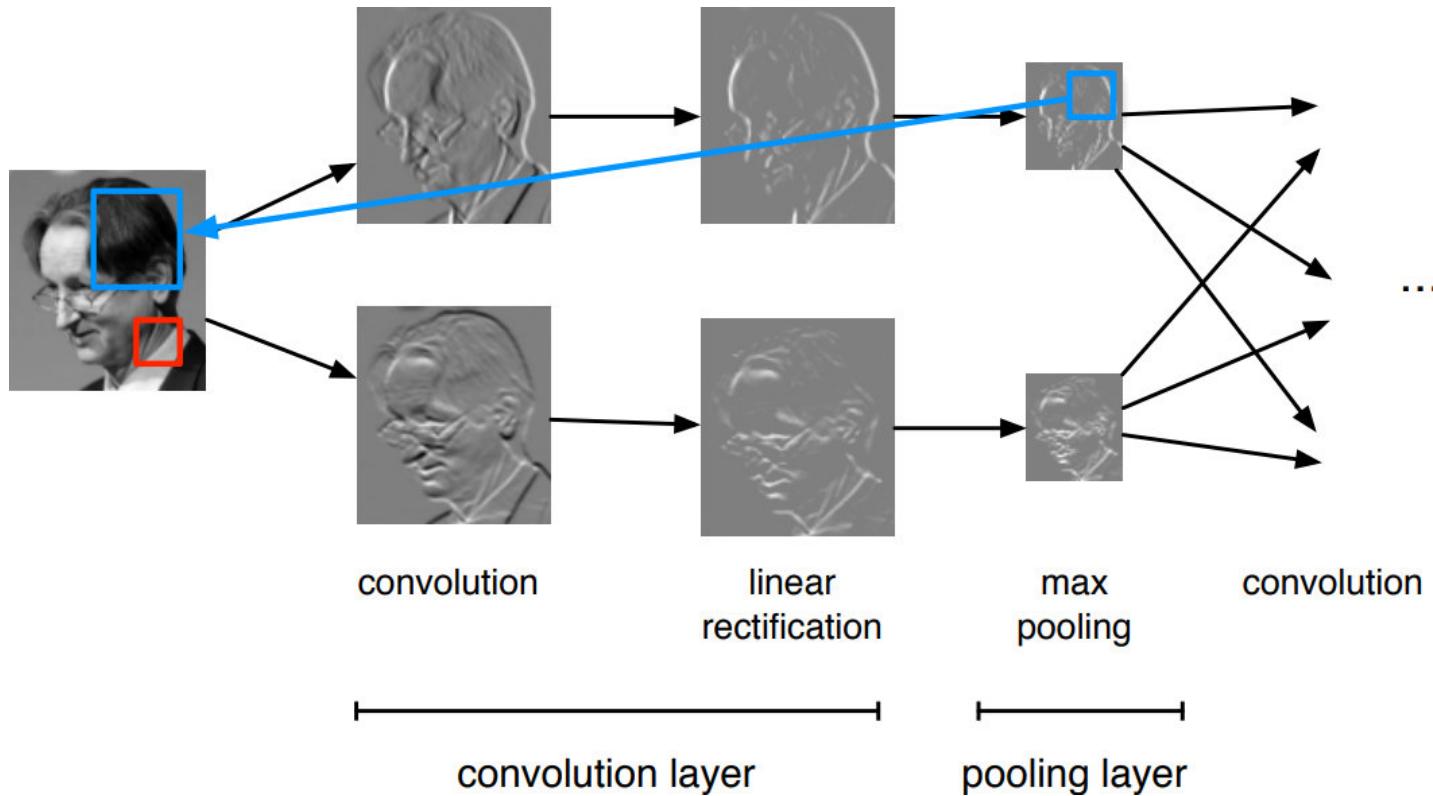
# 卷积神经元网络

- 一种特别的多层前向神经元网络
- 起源：手写体识别
- 常用于图像视觉应用、文本处理



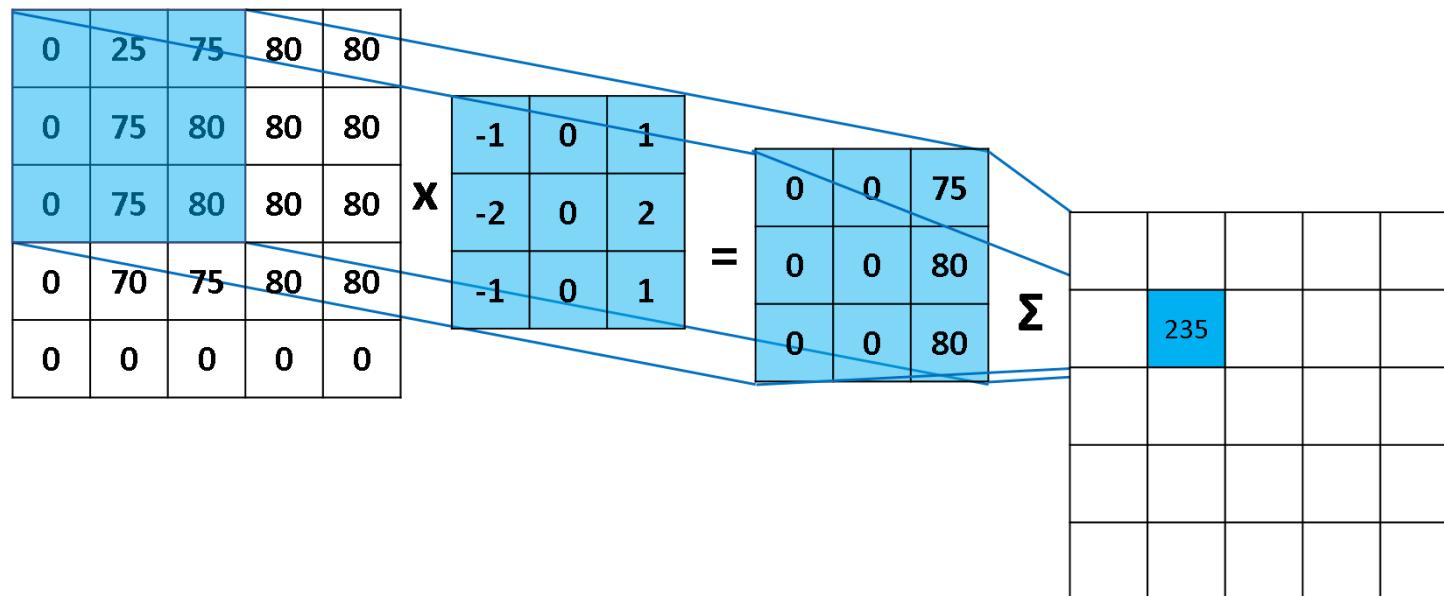
# 组成

- 卷积层
  - 卷积 + 非线性激活函数 (如ReLU)
- 池化层



# 复习：卷积操作

二维卷积，对应位置相乘，然后相加



# 复习：图像卷积

滤波器在图片上滑动，进行卷积操作

7	2	3	3	8
4	5	3	8	4
3	3	2	8	4
2	8	7	2	7
5	4	4	5	4

\*

1	0	-1
1	0	-1
1	0	-1

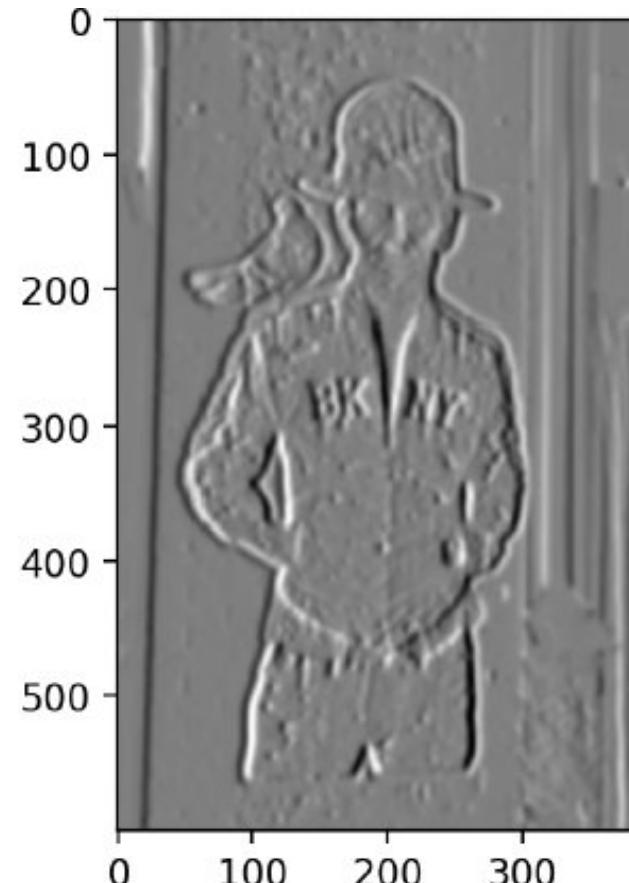
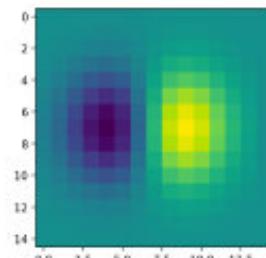
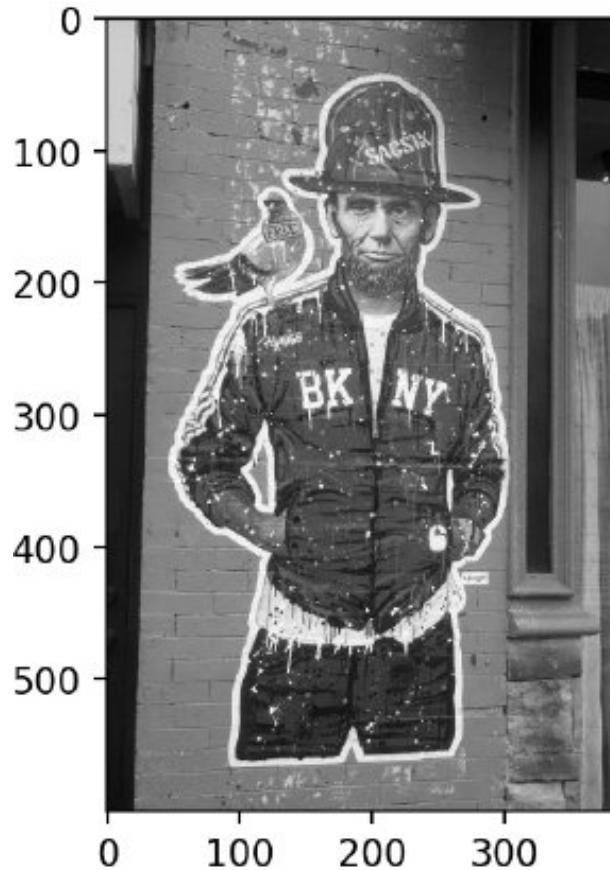
=

6		

$$7 \times 1 + 4 \times 1 + 3 \times 1 + \\ 2 \times 0 + 5 \times 0 + 3 \times 0 + \\ 3 \times -1 + 3 \times -1 + 2 \times -1 \\ = 6$$

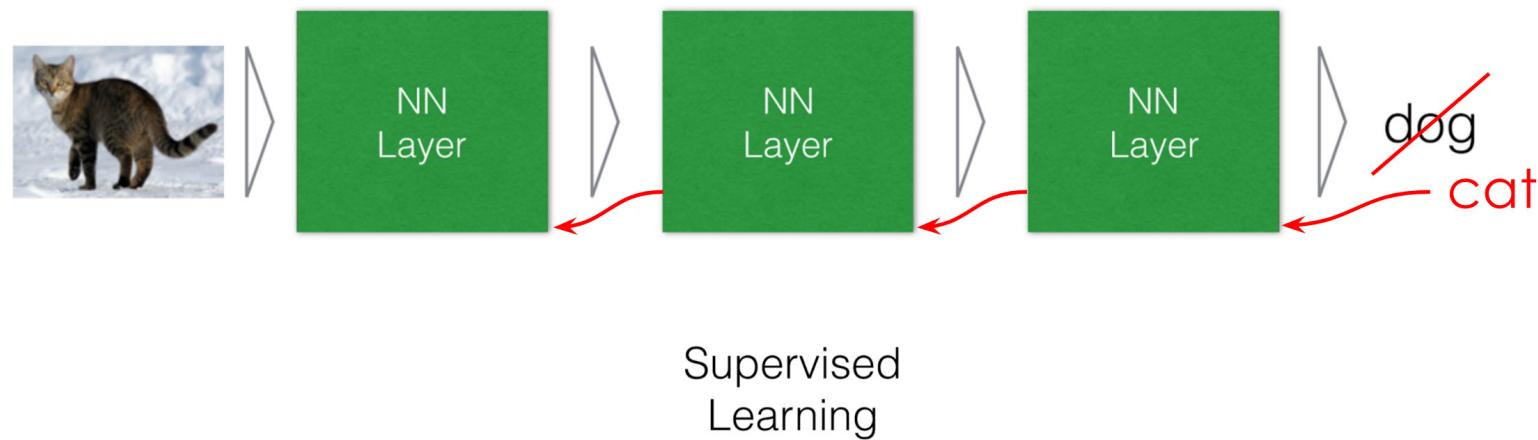
# 复习：图像卷积效果

选择合适卷积核（滤波器），卷积计算图像像素梯度



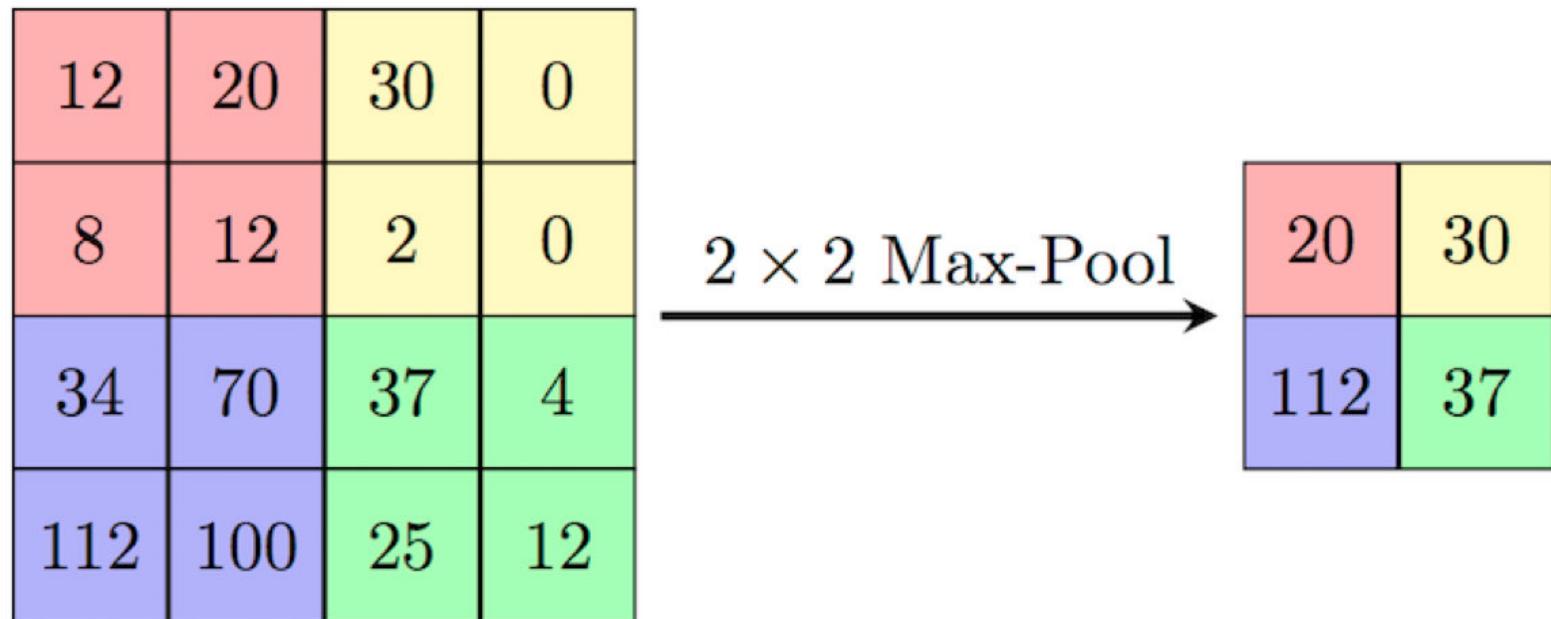
# 深度卷积神经元网络

- 将原始数据直接送入多层神经元网络进行学习
- 多次卷积池化
- 出现错误，一路调整卷积核



# 池化

采样降低数据量



最大池化：Max Pooling

# LeNet

- 手写体识别
- 1988年, LeCun

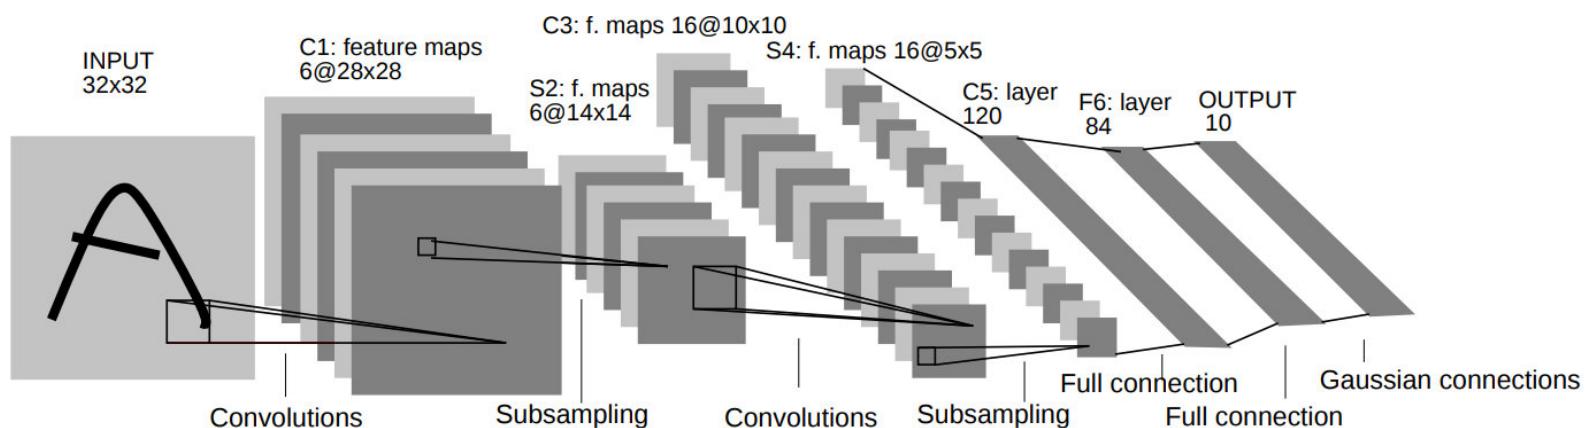
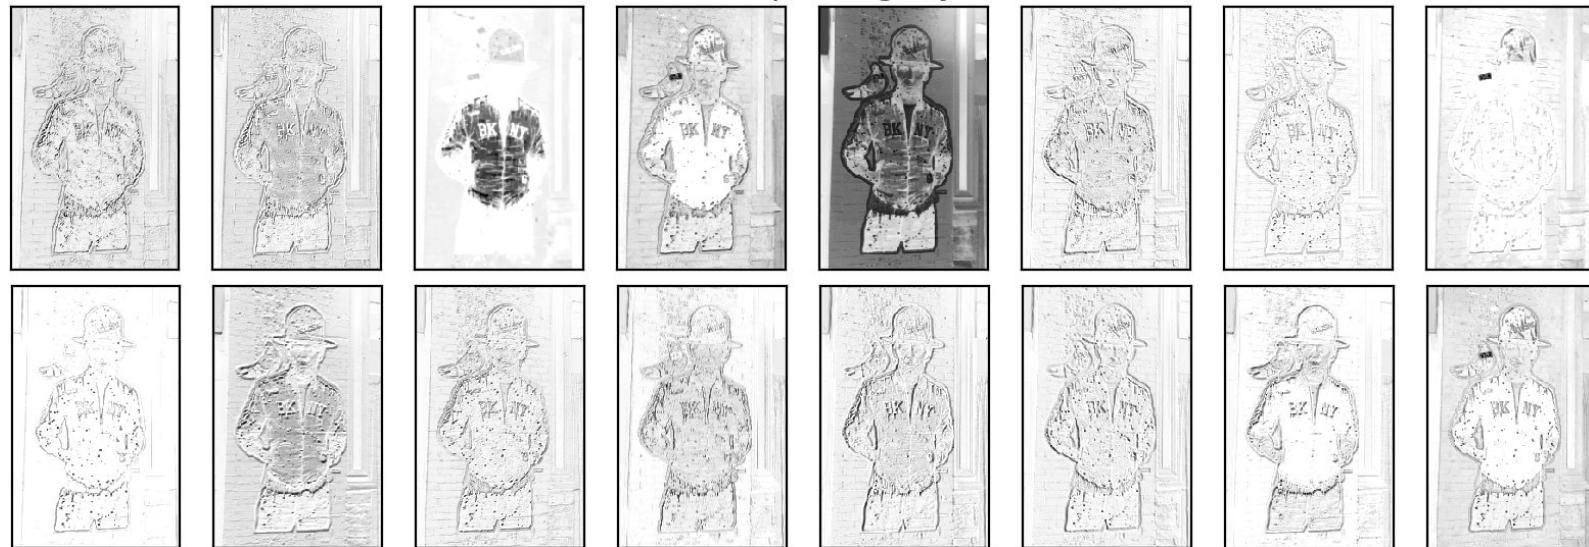


Fig. 2. Architecture of LeNet-5, a Convolutional Neural Network, here for digits recognition. Each plane is a feature map, i.e. a set of units whose weights are constrained to be identical.

# 图像处理效果

经过第一层卷积和池化

after first pooling layer



# 图像处理效果

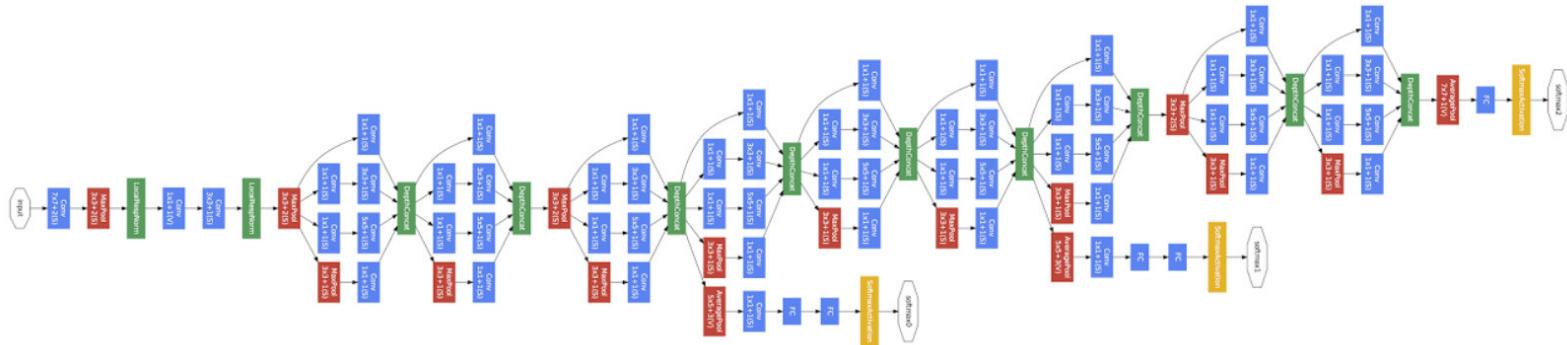
经过第二层卷积和池化

after second pooling layer



# 深度CNN

实际应用的模型层次非常多



GoogleNet

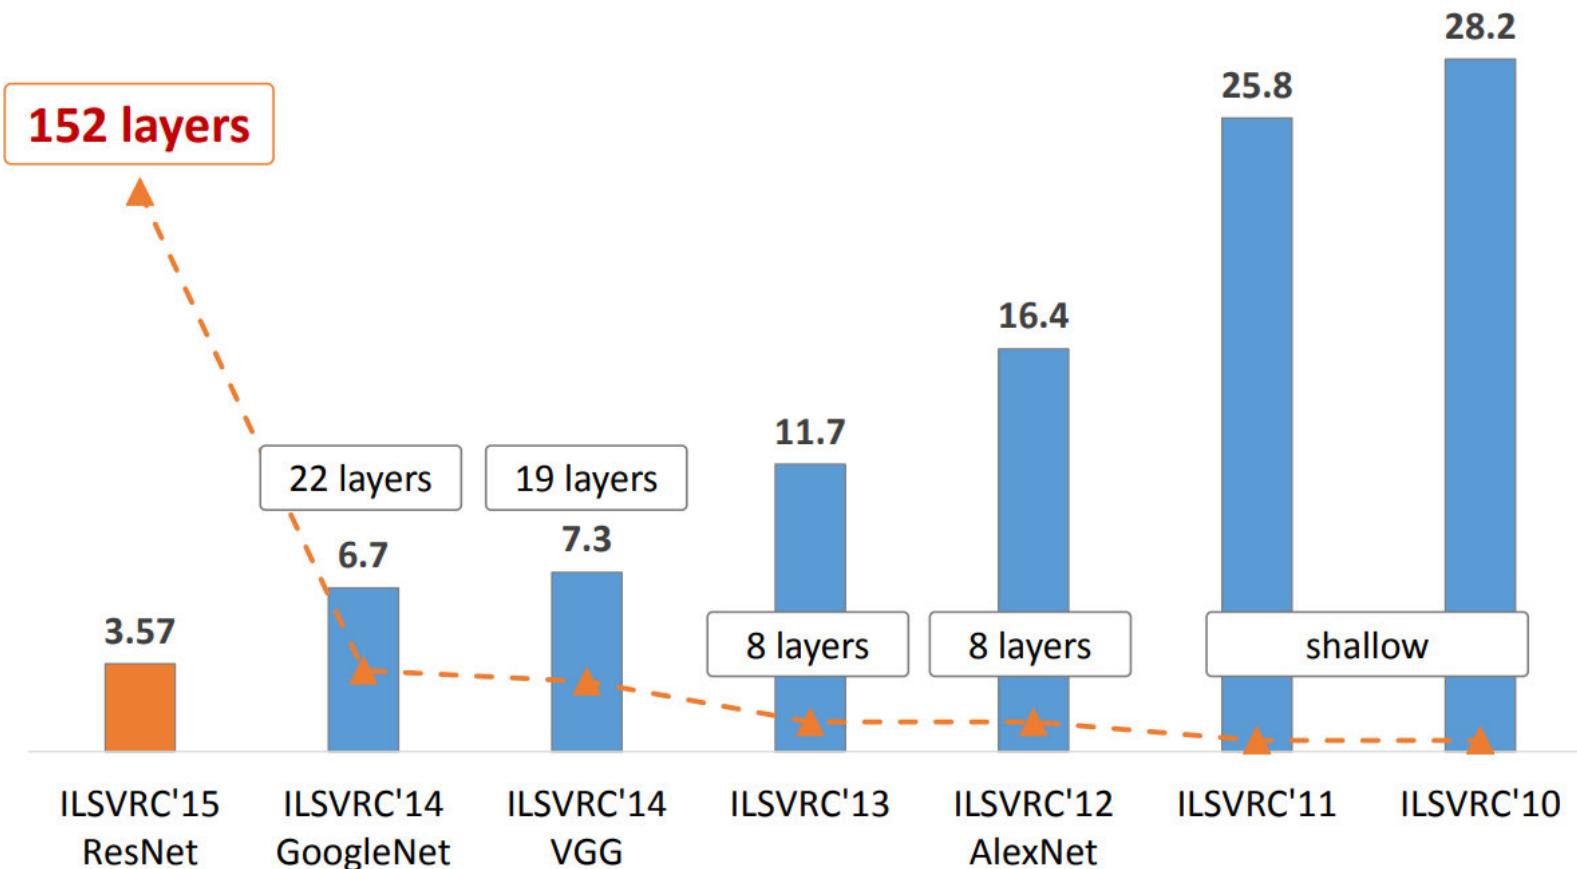
# GPU

- 几千万像素、上千万参数需要计算、调整
- 利用GPU的数千计算单元并行计算



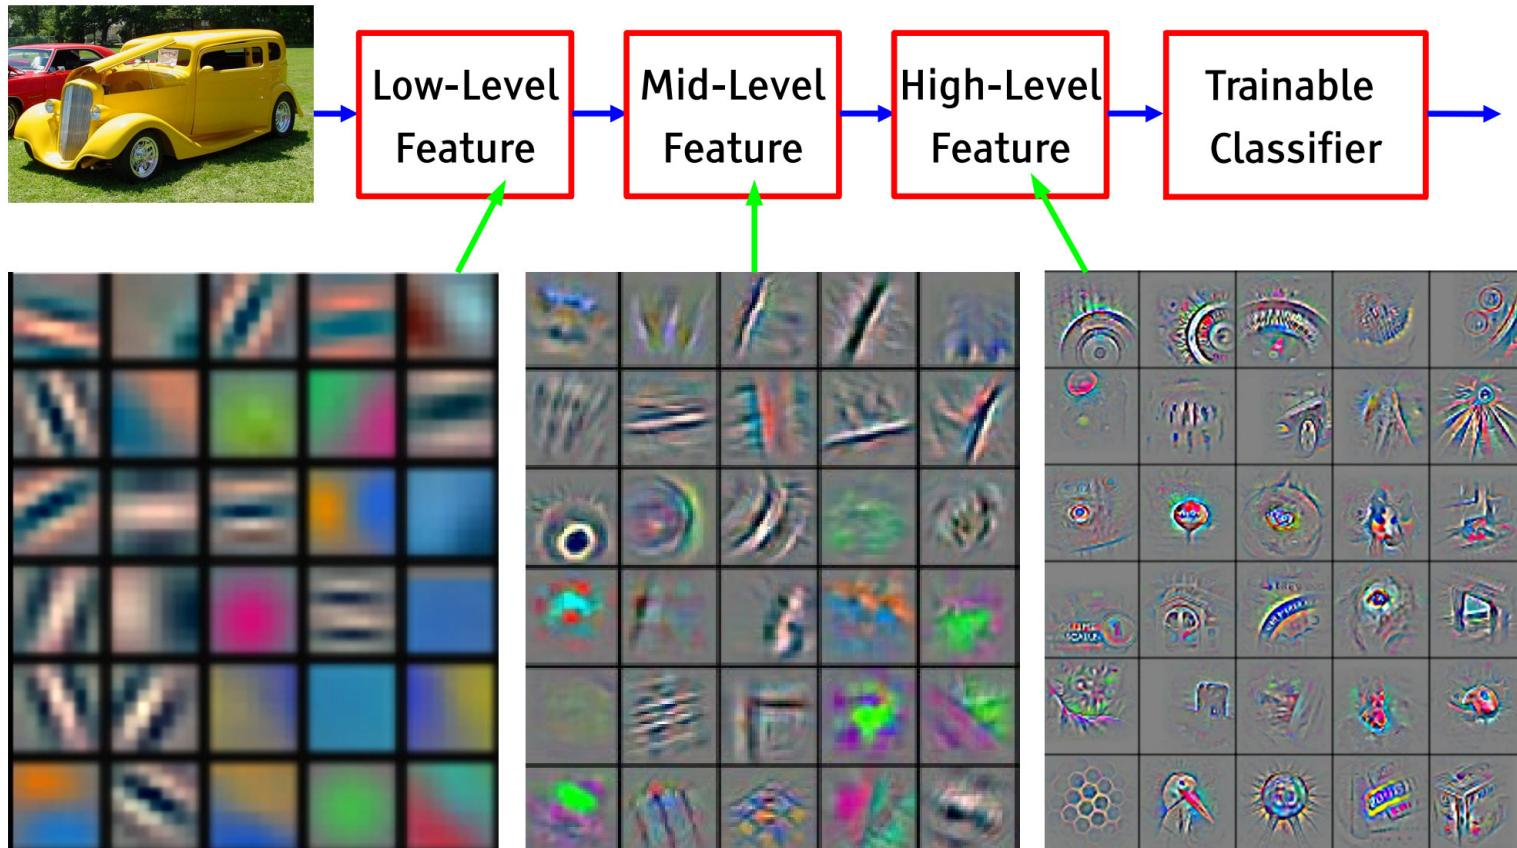
# 深度带来性能极大改善

ImageNet目标识别图像数据集



# 对各层卷积核的理解

- 底层提取简单特征，高层提取复杂特征



Feature visualization of convolutional net trained on ImageNet from [Zeiler & Fergus 2013]

# CNN演示

- Andrej Karpathy ConvNetJS
- <https://cs.stanford.edu/people/karpathy/convnetjs/demo/mnist.html>
- 在浏览器里训练CNN，实验MNIST手写体识别任务

# 内容

- 算法
- 模型
- 性能

# 性能

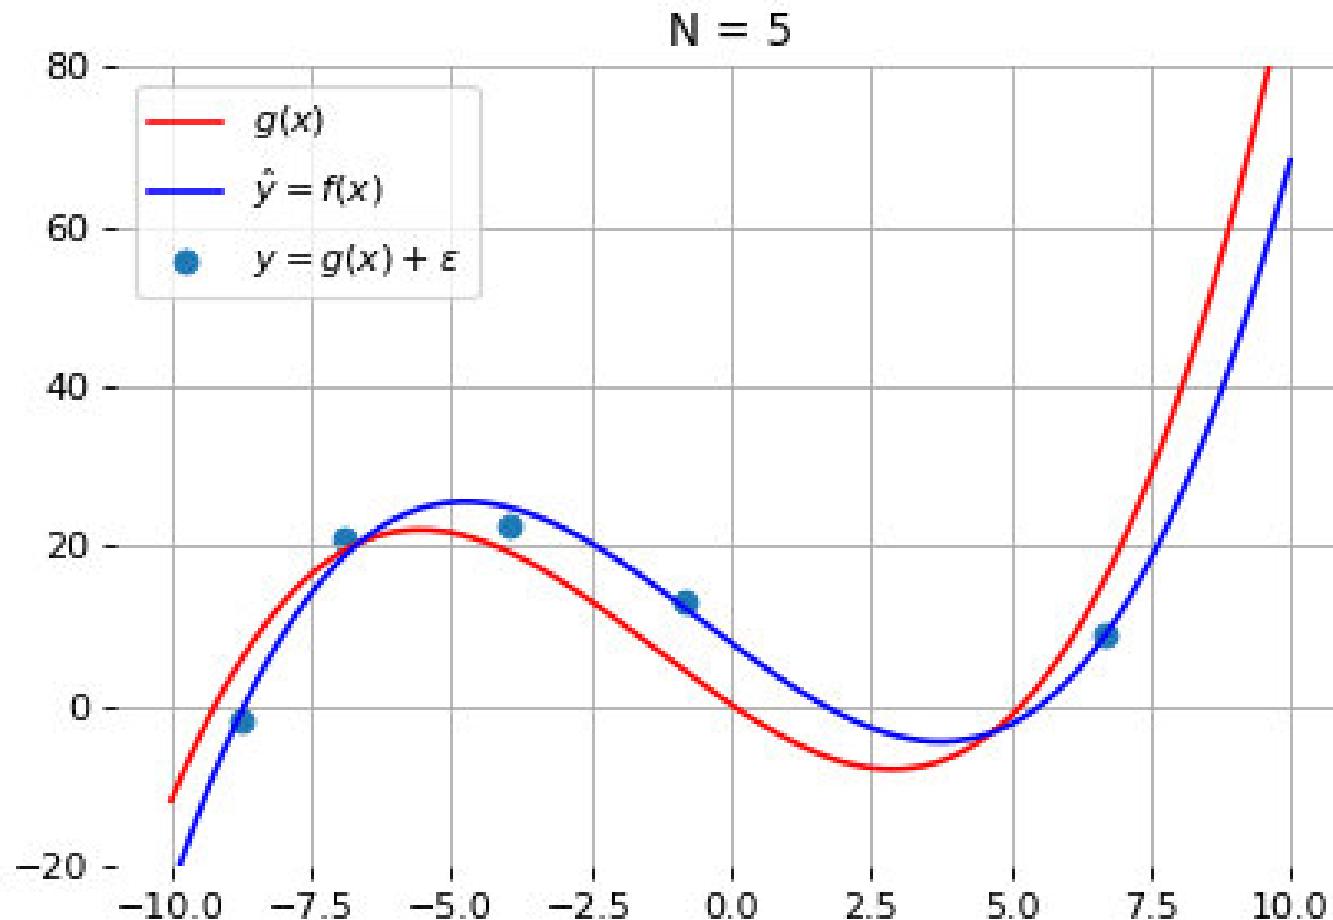
- 数据
- 模型

## 1) 数据

好的数据是成功的关键

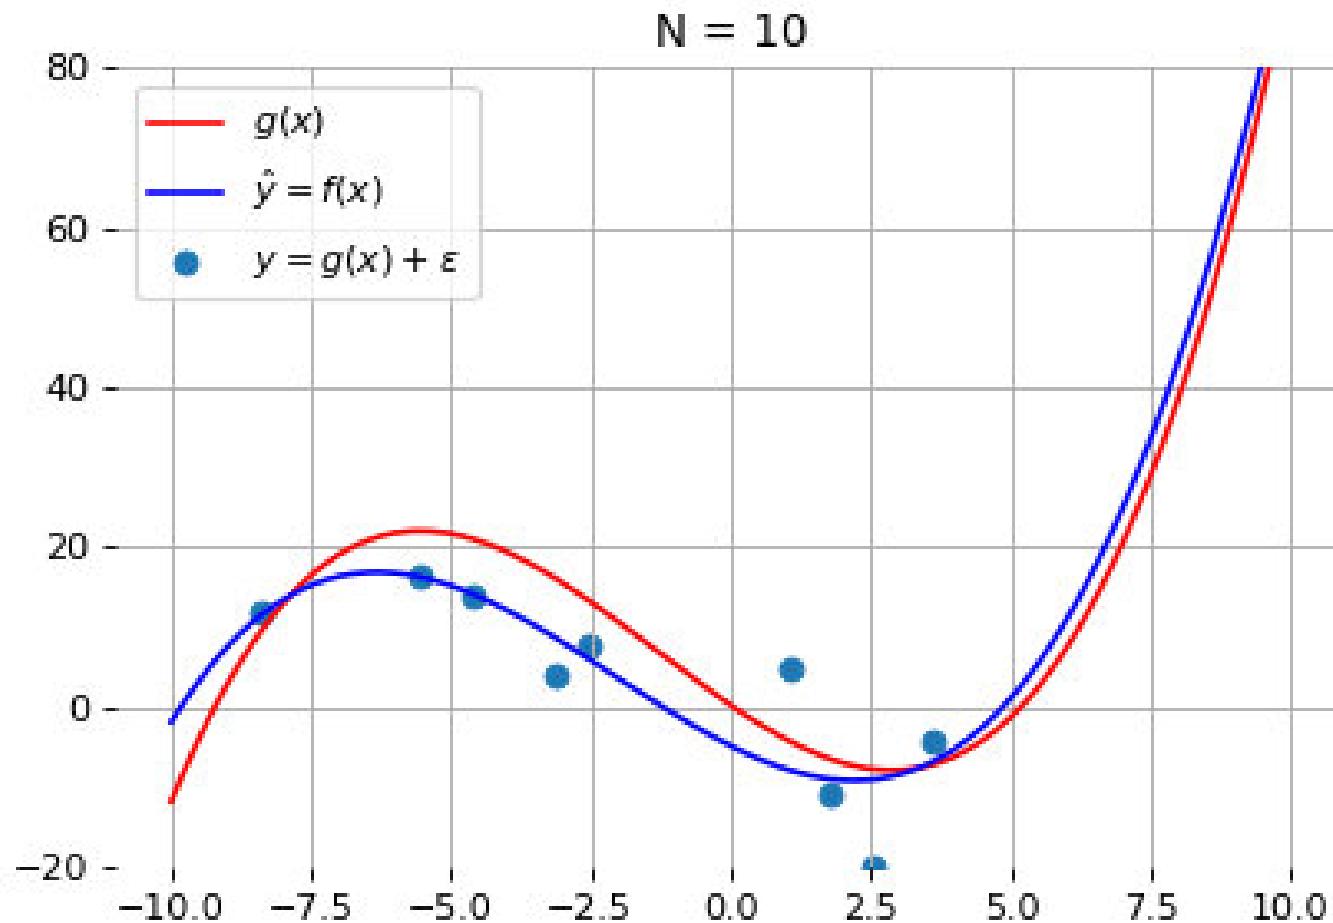
# 数据量对结果的影响

数据量少，模型误差大



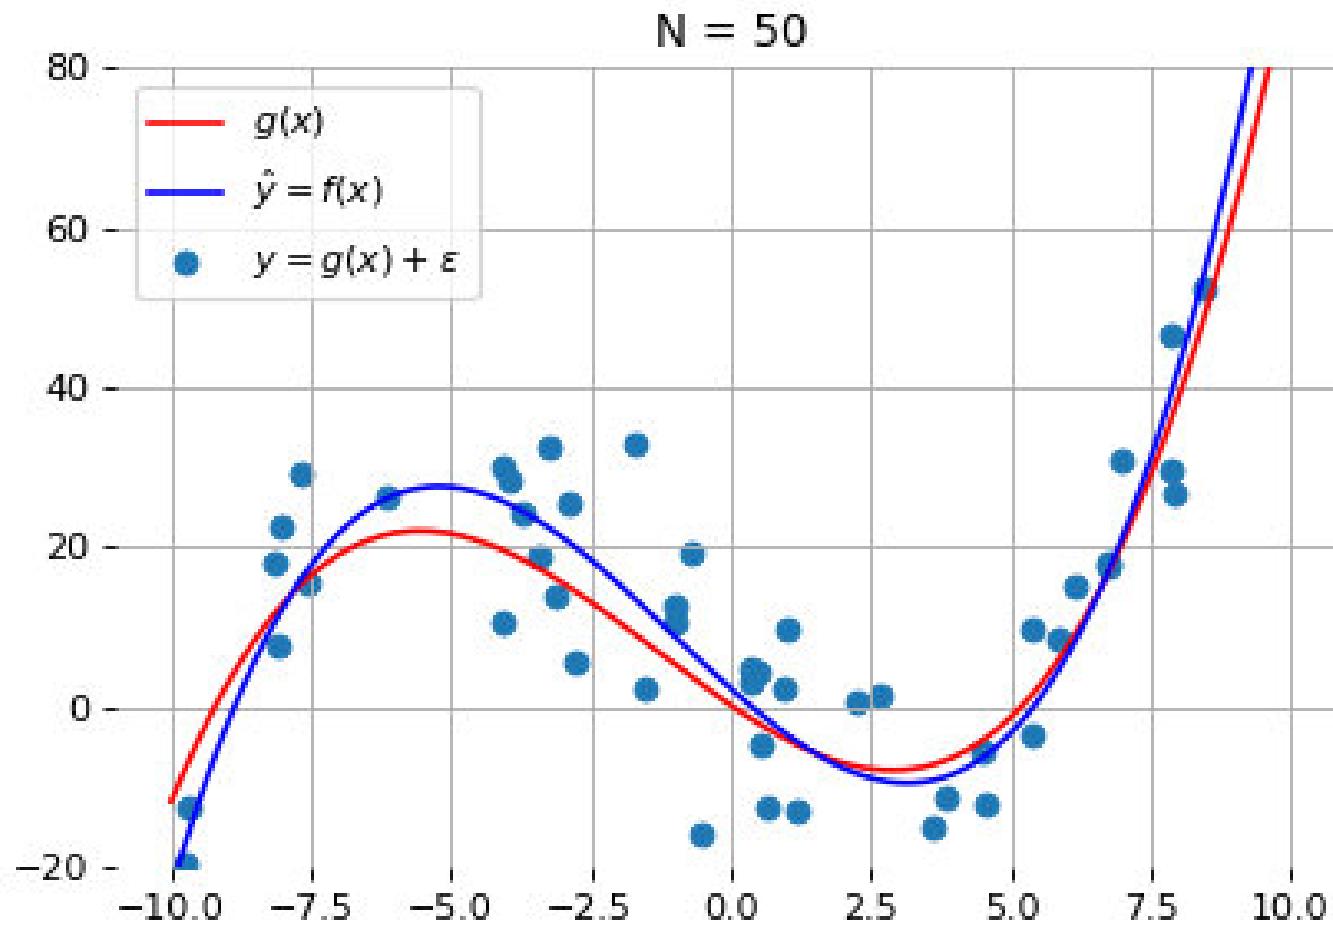
# 数据量对结果的影响

随着数据量增长，模型误差减少



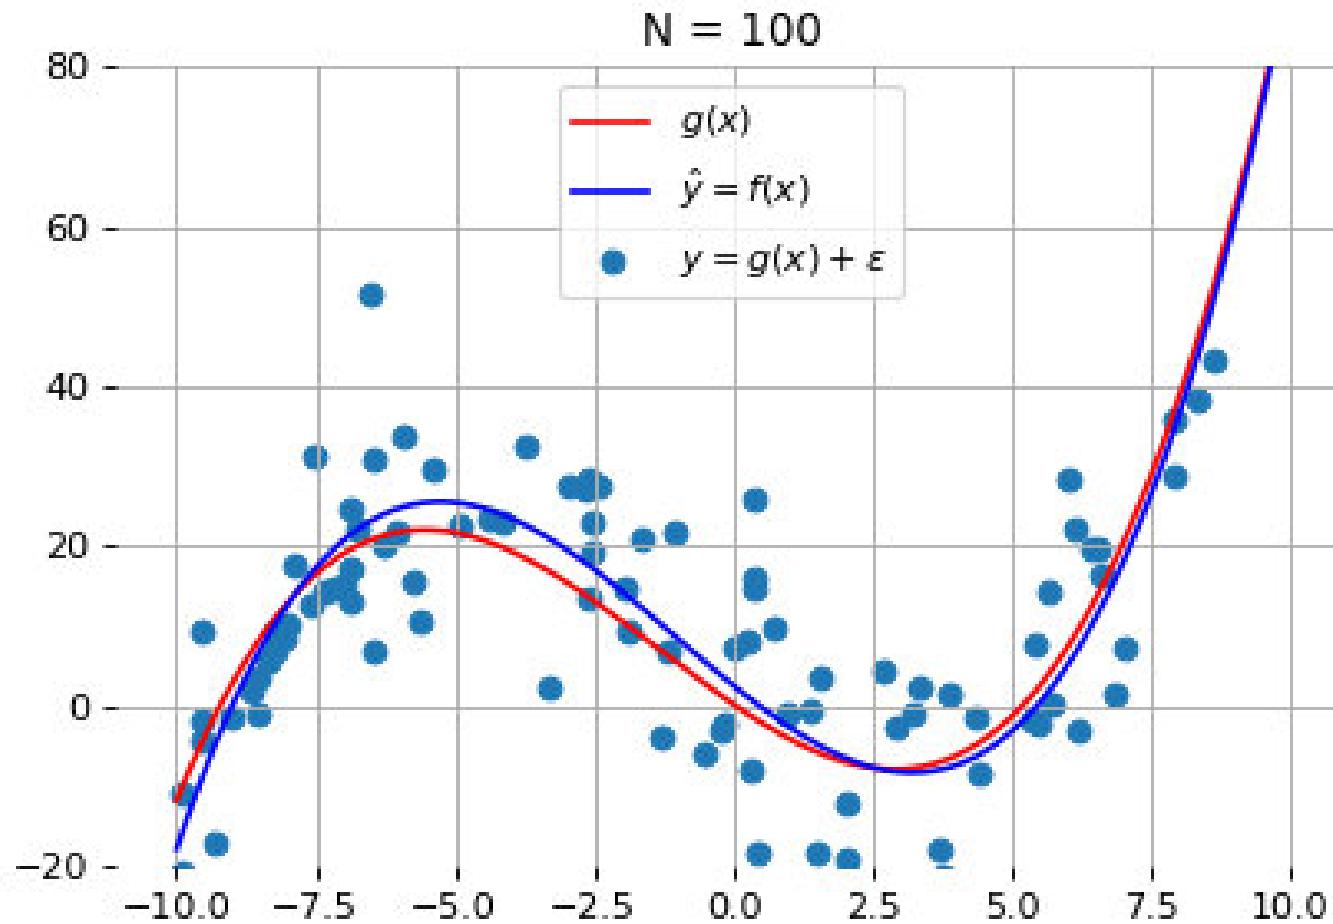
# 数据量对结果的影响

随着数据量增长，模型误差减少



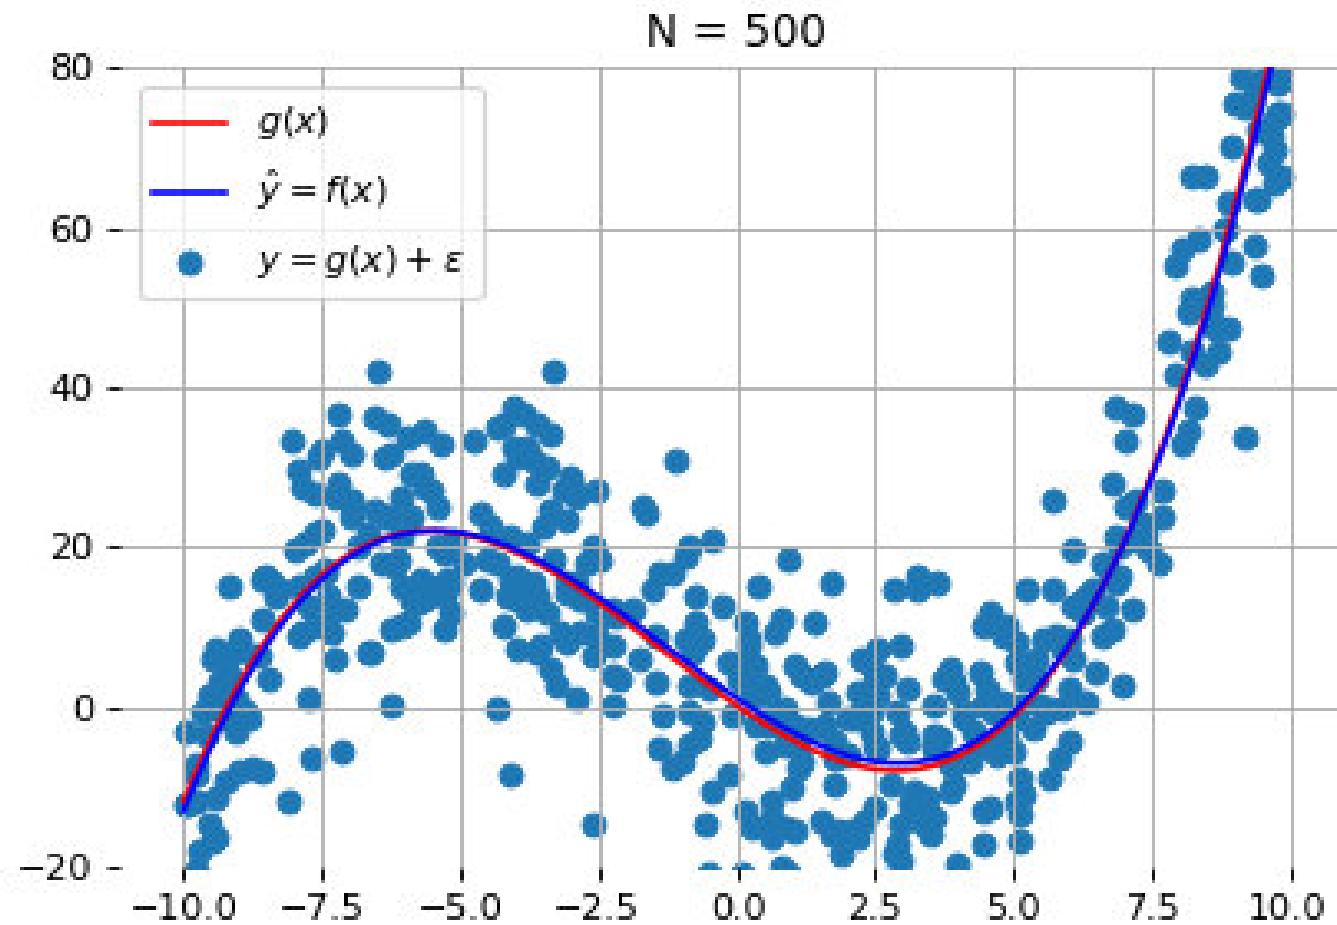
# 数据量对结果的影响

随着数据量增长，模型误差减少



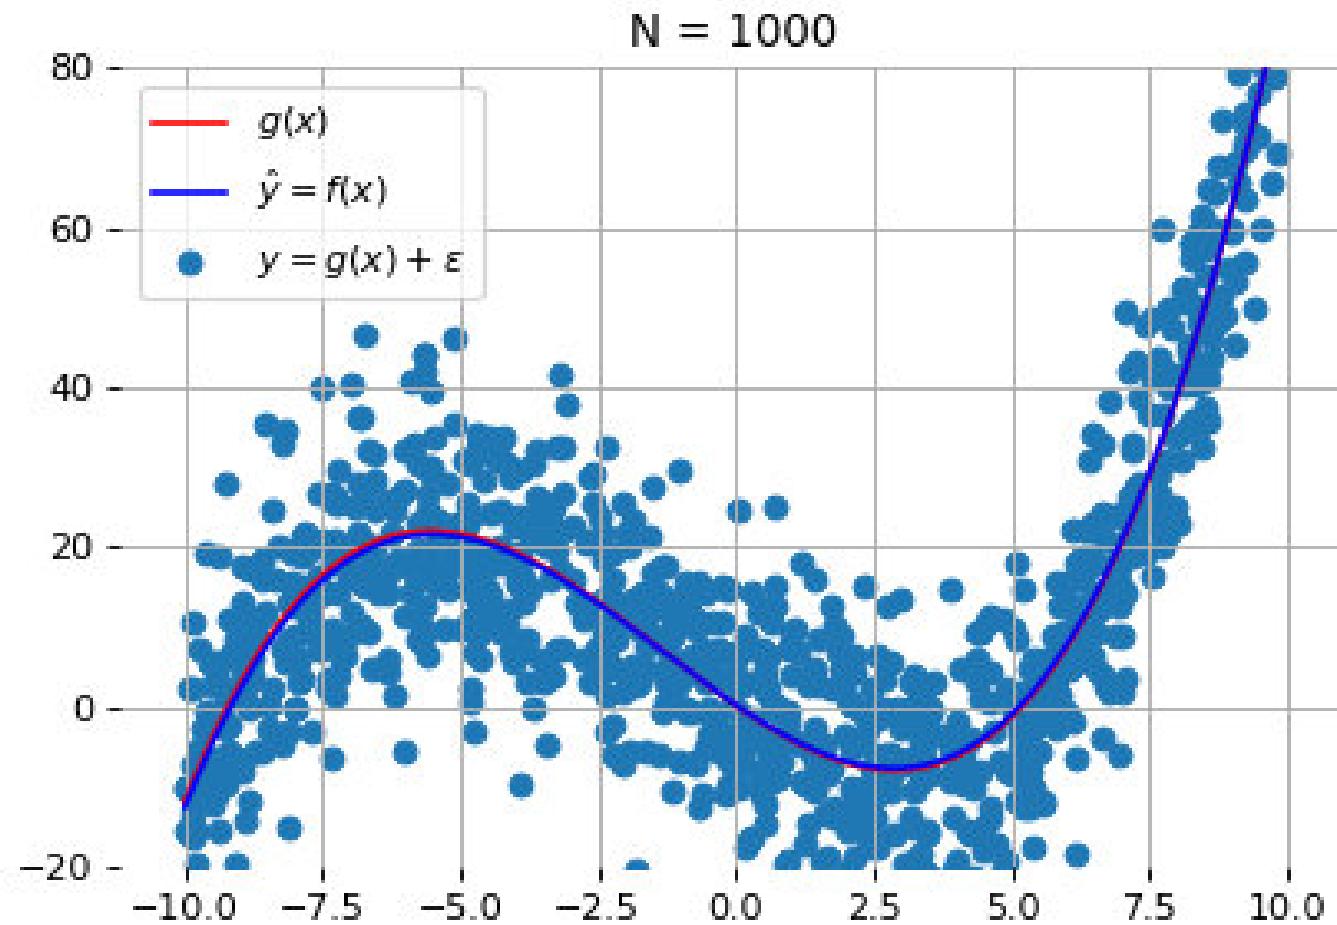
# 数据量对结果的影响

随着数据量增长，模型误差减少



# 数据量对结果的影响

随着数据量增长，模型误差减少

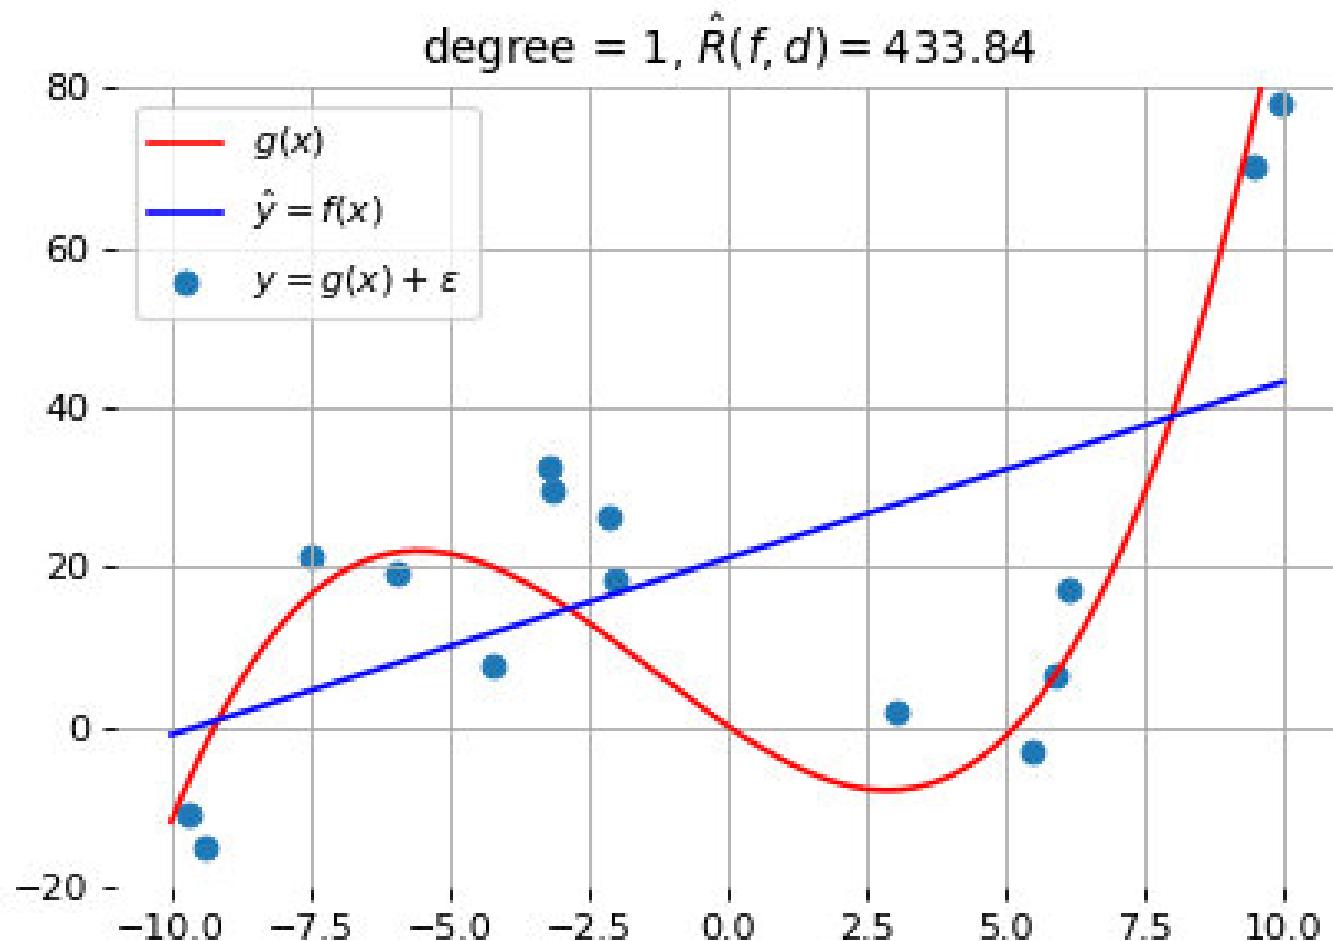


## 2) 模型

模型选择非常重要

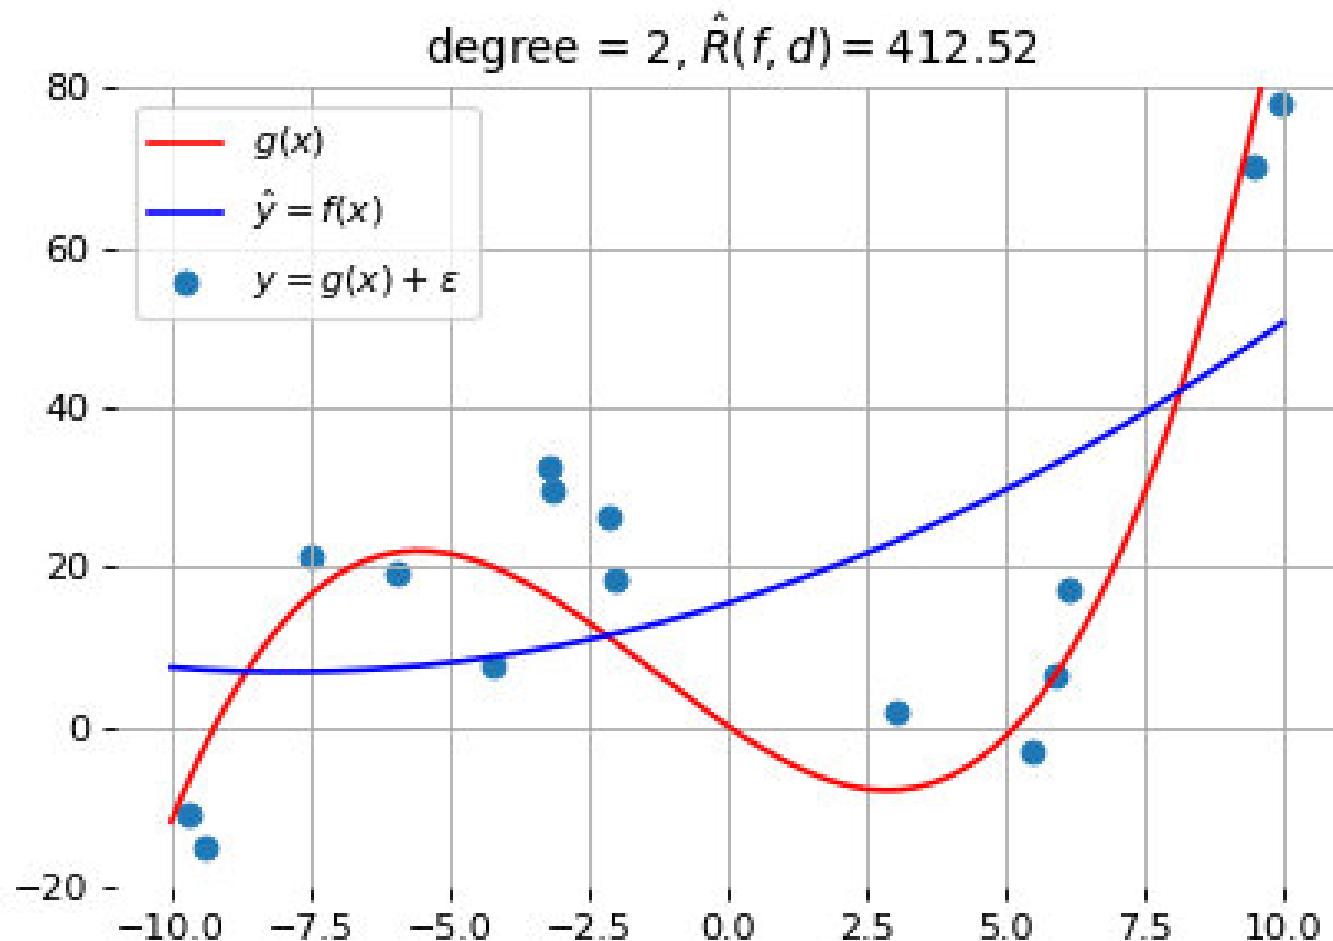
# 模型能力

模型能力不够，欠拟合



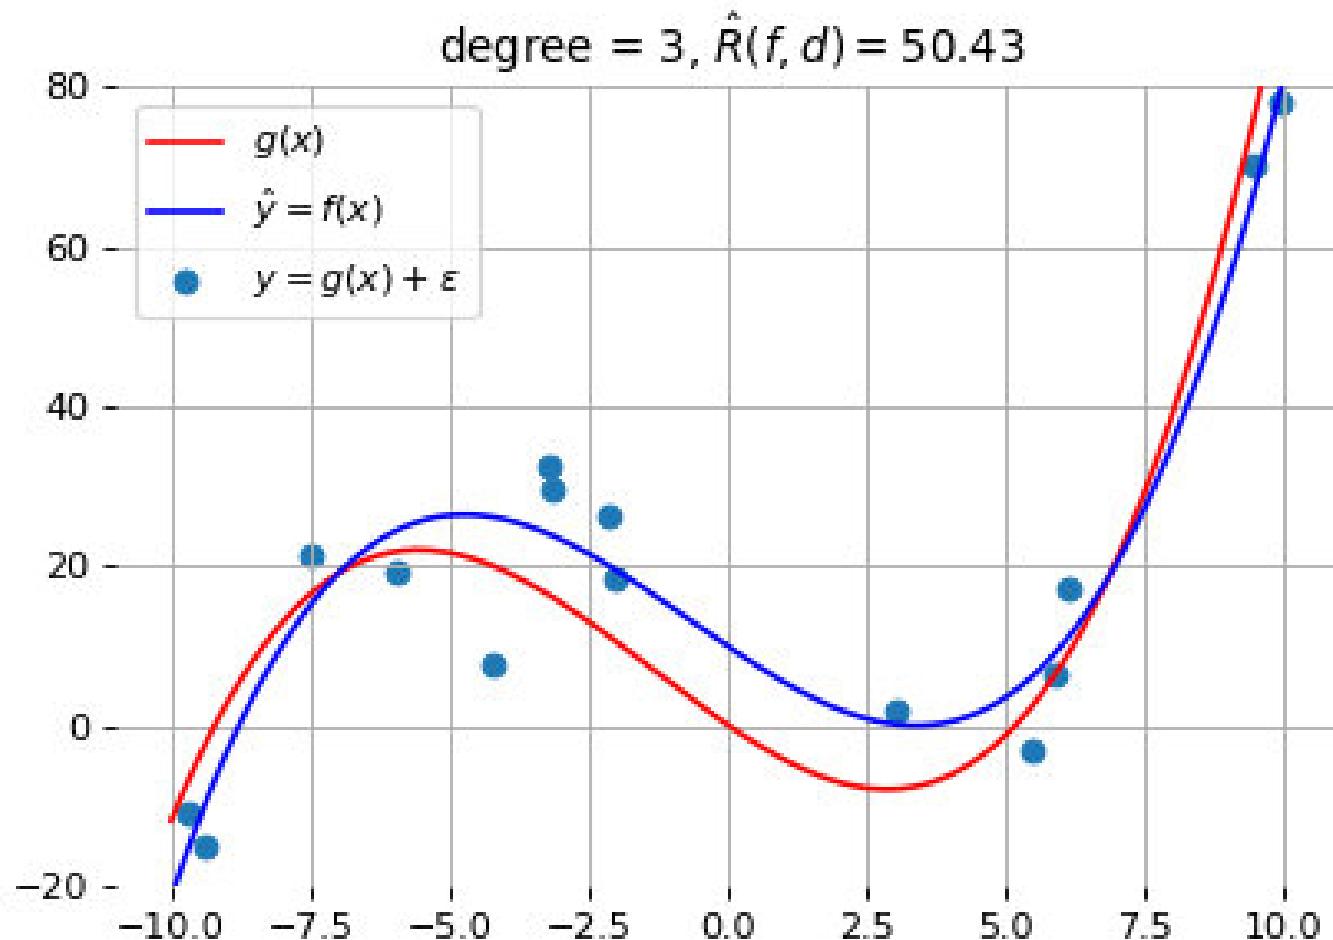
# 模型能力

模型能力不够，欠拟合



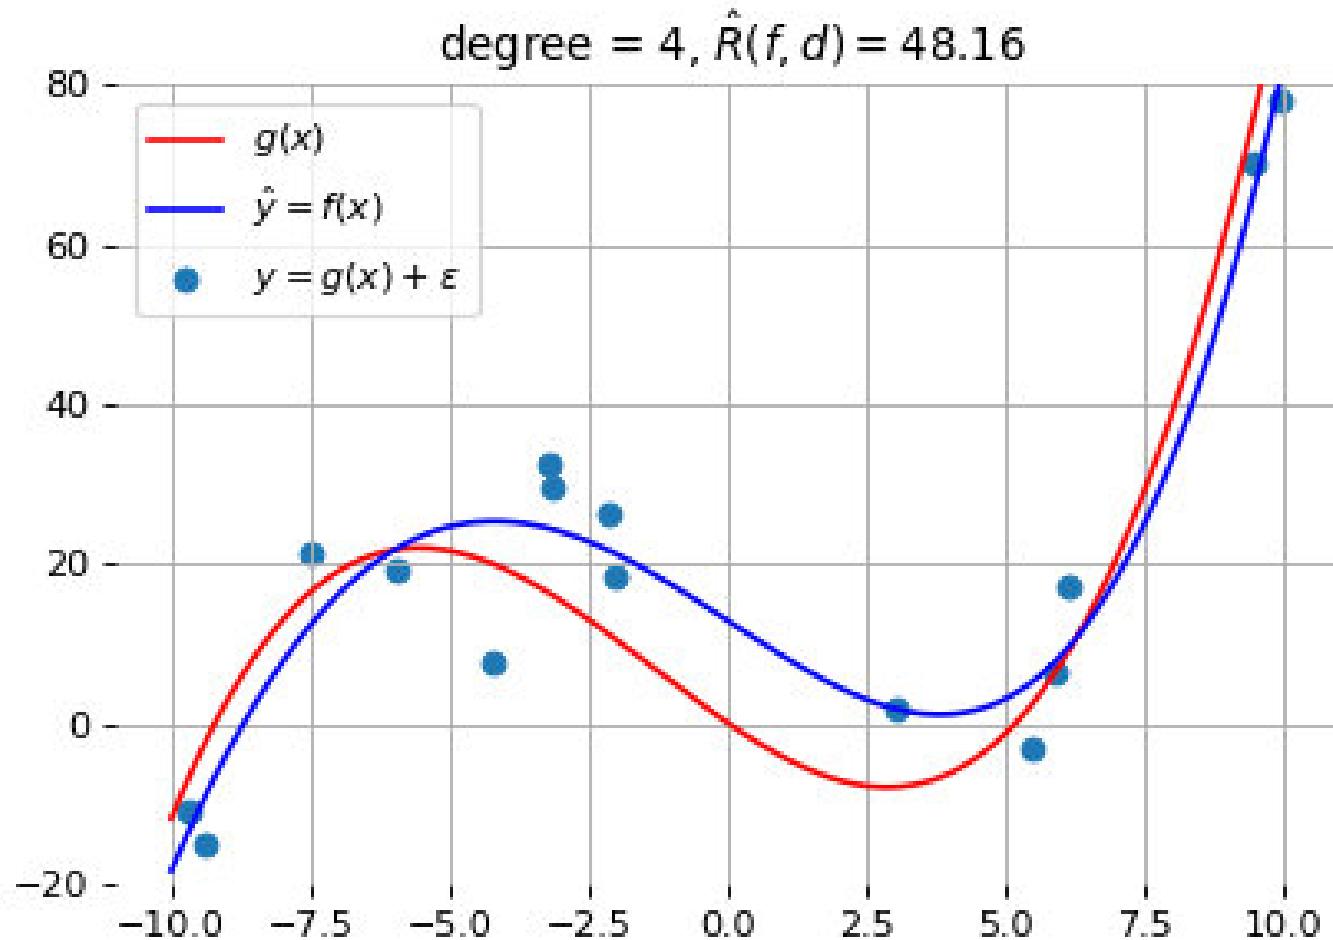
# 模型能力

模型能力适中



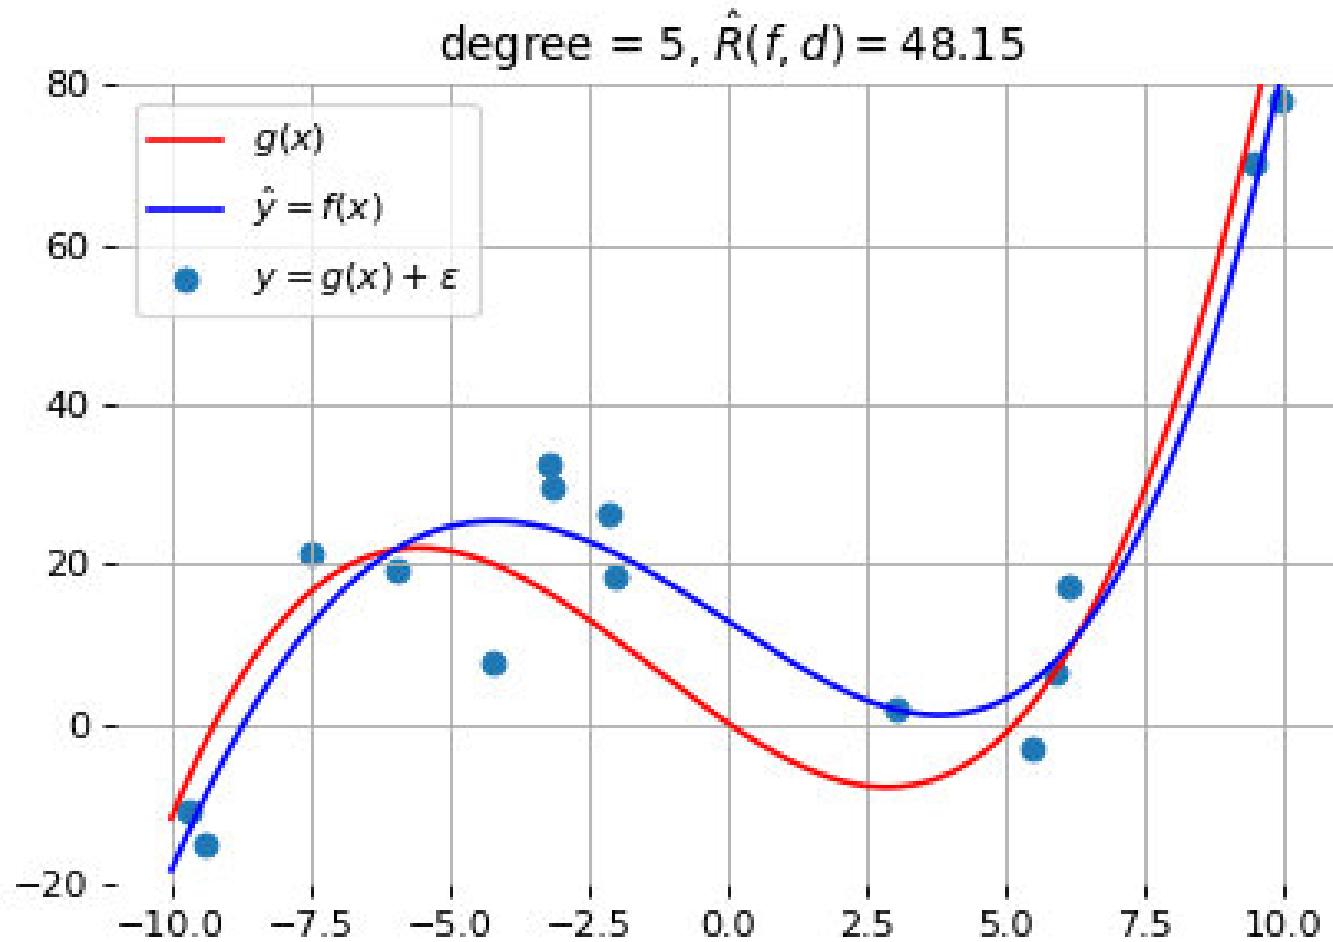
# 模型能力

模型能力适中



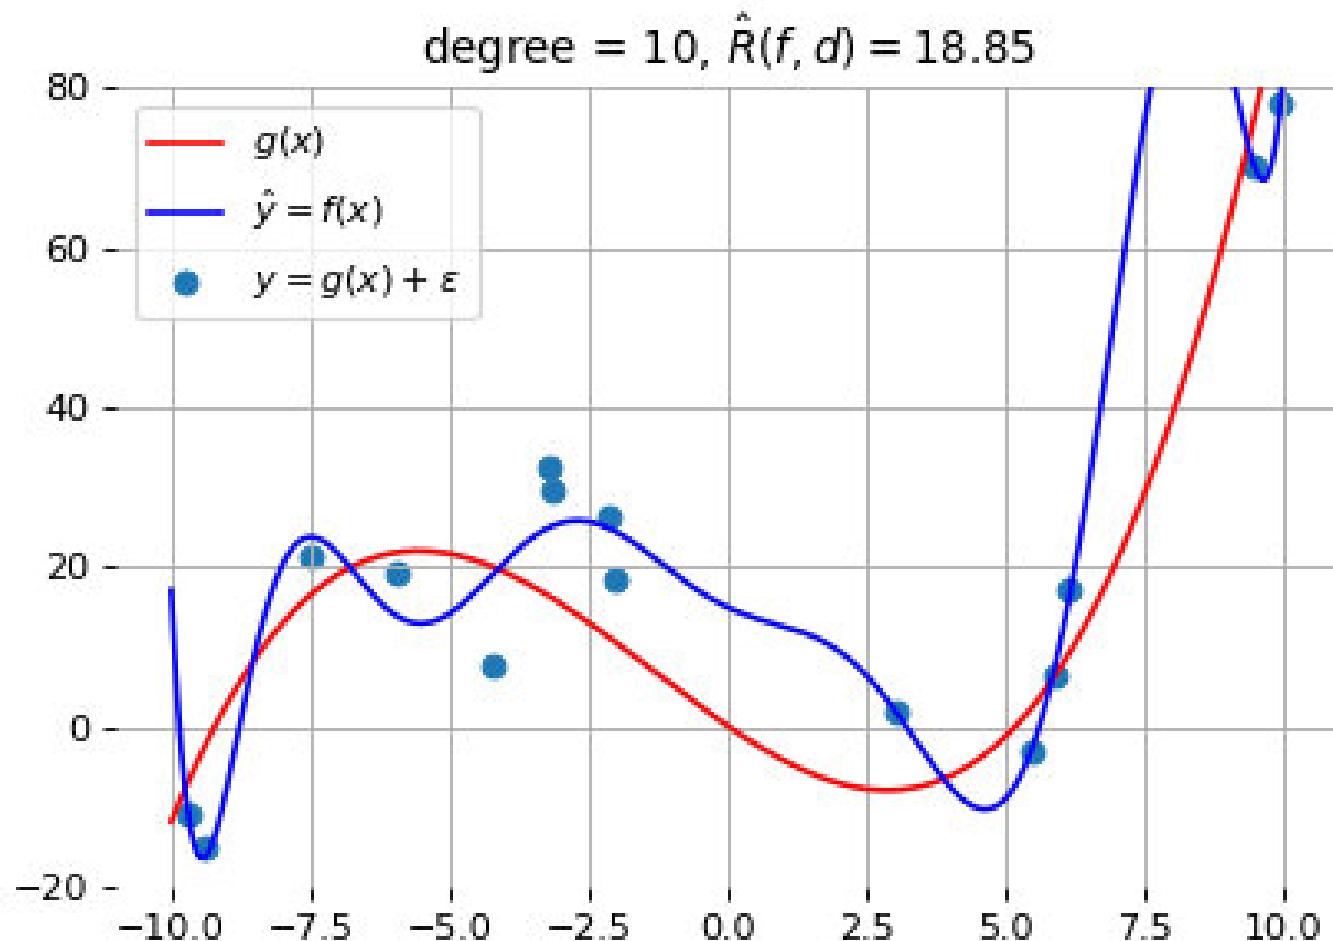
# 模型能力

模型能力适中



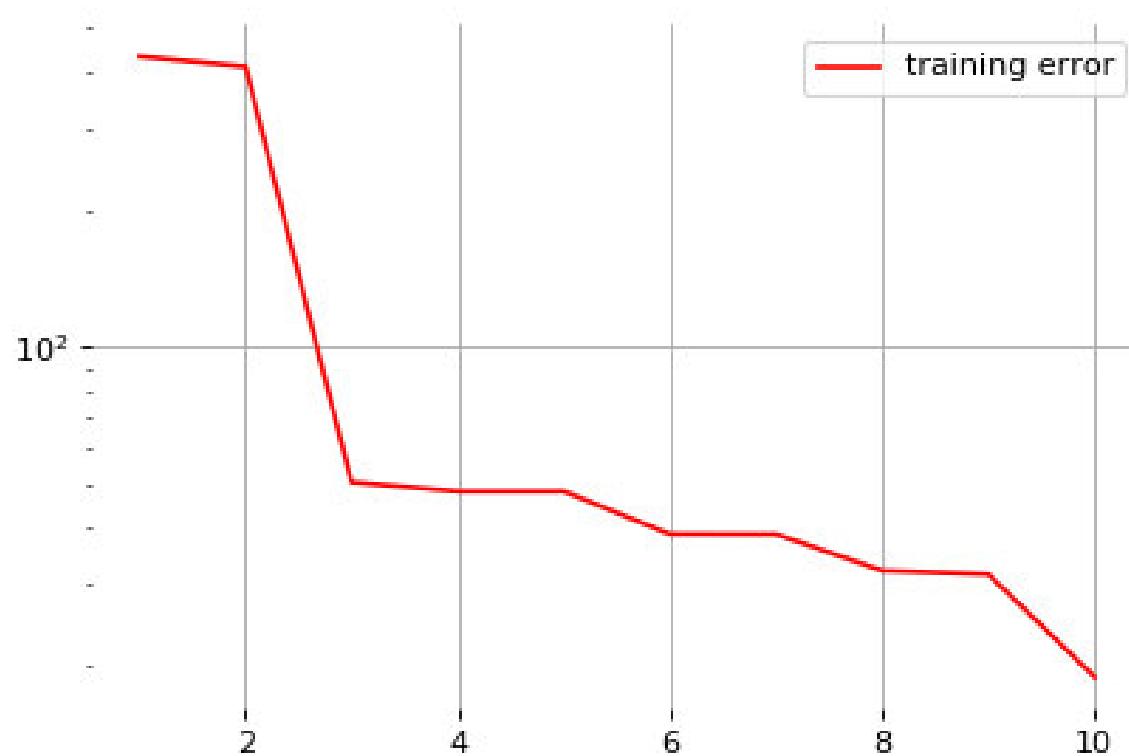
# 模型能力

模型能力太强，过拟合



# 模型能力

- 训练集上，模型错误随模型能力增长一直下降
- 但最后的下降，是过拟合了



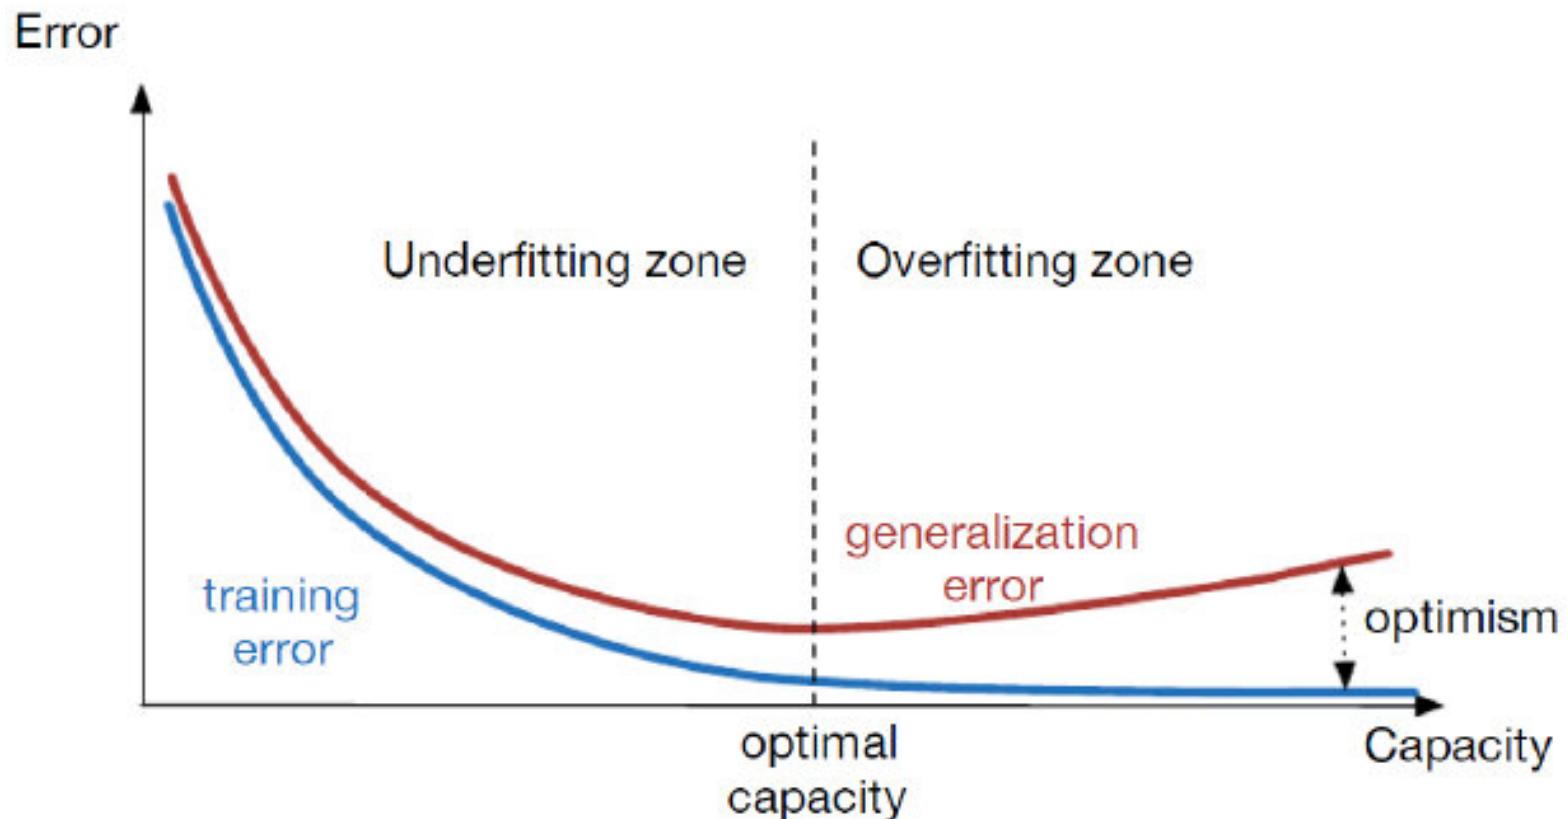
# 过拟合

- 过拟合导致模型在测试集上错误上升



# 模型能力

选择合适的模型非常重要



# 模型选择

- 深度神经网络不是唯一的机器学习算法
- 完全可以基于干净的数据集、更简单的算法（如线性回归）来解决问题
- 记住奥卡姆剃刀准则

# 奥卡姆剃刀准则

简约至上

"The explanation requiring the fewest assumptions is most likely to be correct"

"解释能力相同情况下， 假设越少越好"

# 奥卡姆剃刀

- Occam's Razor
- 14世纪逻辑学家，奥卡姆的威廉（William of Occam）提出
- “切勿浪费较多东西，去做‘用较少的东西，同样可以做好的事情’”

# 奥卡姆剃刀

- 关于同一个问题有许多种理论，每一种都能作出同样准确的预言，那么挑选其中使用假定最少的
- 尽管越复杂的方法通常能做出越好的预言，但是在不考虑预言能力（即结果大致相同）的情况下，假设越少越好
- 在结果大致相同的情况下，模型越简单越好

# 小结

- 算法
  - 有监督、无监督
- 模型
  - 机器学习、深度学习
  - 前向神经元网络、卷积神经元网络
- 性能
  - 数据、模型

# 复习题I

- 什么是有监督学习？什么是无监督学习？
- 图片分类是有监督学习，还是无监督学习？
- 聚类是有监督学习，还是无监督学习？
- 两种最典型的深度神经元网络，分别是什么？
- 模型的能力不够，会过拟合还是欠拟合？
- 模型的能力太强，会过拟合还是欠拟合？
- 什么是奥卡姆剃刀原则？